

BACE-1 抑制剂活性预测： 分子表征、结构对接与 Conformal 可信度评估

复旦大学药学院《AI 赋能药物设计发现前沿》期末实验报告

姓名/学号：_____

授课教师：戚逸飞 / 王任小

算力：8 × NVIDIA RTX 5880 Ada (48GB)

日期：2026 年 6 月

目录

摘要

β -secretase 1 (BACE-1) 是阿尔茨海默病的关键药物靶点。本报告以 BACE 数据集 (1513 个分子) 的抑制活性 pIC50 预测为核心任务，把一个药物设计问题从数据、五类分子表征建模、三维结构对接，到“何时可以相信预测”的 conformal 可信度评估，做成一条完整闭环；并将同一套方法学扩展到全部 6 个 MoleculeNet 数据集做交叉验证。

核心结果：图网络 (Chemprop D-MPNN) 在 BACE 上 Pearson R = 0.835、MAE = 0.604 双双最佳，其余四类表征聚于 R $\approx$ 0.80；共晶配体重对接 (redock) RMSD 0.92 Å 验证了对接位姿几何，但 Vina 打分经配体效率归一化后与活性相关性归零 (Pearson +0.10)，即位姿可信而打分不预测活性；conformal 在 BACE 有效覆盖下给出约 ± 1.3 pIC50 的最紧合法区间，并量化“最紧 $\neq$ 有效”——低相似度新骨架子群系统性欠覆盖。全程以阴性对照与数据泄漏审计自检。

1 引言

β -secretase 1 (BACE-1) 负责切割淀粉样前体蛋白、生成 β -淀粉样肽 (A β)，是抑制 A β 斑块形成、治疗阿尔茨海默病的关键药物靶点；准确预测候选分子对 BACE-1 的抑制活性，可在早期高效筛选弱活性化合物、加速先导发现。

本课程作业要求：选择课程介绍的某项人工智能药物设计预测任务，完成数据整理、模型构建、训练与分析，并撰写书面报告与课堂汇报。我们选择 BACE-1 抑制活性预测作为核心任务——在 6 个候选任务中，它是唯一能把课程的两类建模策略、三维表征、结构对接与可信度评估串成完整流程的任务：既能比较“SMILES $\rightarrow$ 编码器 $\rightarrow$ 机器学习”（策略一）与“SMILES $\rightarrow$ 二维分子图 $\rightarrow$ 图神经网络”（策略二）两条路线，又能引入蛋白晶体结构做对接，正中结构计算的核心。为检验方法学的普适性，我们再将同一套流程扩展到全部 6 个 MoleculeNet 数据集做交叉验证 (§4)。

2 数据与方法

2.1 BACE 数据集

BACE 数据集含 1513 个 β -secretase 抑制剂，预测连续 pIC50（回归任务；指标 MAE / Pearson R），采用数据集预定义的训练 / 验证 / 测试划分。所有 SMILES 经 RDKit canonical 化一次，解析失败者记录数量后剔除（不静默丢弃）；BACE 约 71% 分子立体化学未定义，我们保留 @/@@ 标记、不强制去立体，并在讨论中说明其对 stereo-aware 模型的潜在影响。任何标准化仅在训练折上拟合，防止信息泄漏。

2.2 五类分子表征

我们覆盖课程的两类策略并各取代表模型，额外加入一个三维几何模型作为超纲对照：

- 策略一（SMILES $\rightarrow$ 编码器 $\rightarrow$ ML）：随机森林 + Morgan 指纹 (radius 2, 2048 位)；MolFormer-XL (11 亿分子预训练的序列 Transformer, 47M 参数)；ChemFM-3B (30 亿参数解码器大模型，LoRA 微调)。
- 策略二（SMILES $\rightarrow$ 二维图 $\rightarrow$ GNN）：Chemprop D-MPNN——有向键消息传递网络，在原子（节点）+ 键（边）特征上做图学习。

- 超纲（三维几何）：Uni-Mol，SE(3)-Transformer，显式利用 RDKit ETKDGv3 生成的 3D 构象。

2.3 评估协议

每个（数据集 × 模型）组合跑 3 个随机种子（42 / 1337 / 2024）取均值 ± 标准差。回归报告 MAE 与 Pearson R（课程指标），并辅以 RMSE / Spearman ρ 。回归目标在训练折上 z 标准化（防泄漏），评估时还原到原单位。

2.4 结构对接

从 PDB 4D8C 提取 β -secretase A 链，用 Meeko 准备受体，以共晶配体 BXD 定义口袋盒子（中心 30.58, 6.24, 14.52；尺寸 22×22×26 Å）。BACE 配体经 RDKit 3D 嵌入 + Meeko 转 PDBQT，用 AutoDock Vina 对接。对接前先以共晶配体 BXD 重对接，验证协议能否重现晶体结合模式 (§3.2)。

2.5 Conformal 可信度协议

用 split conformal 给出名义 90% 覆盖的预测区间，以经验覆盖率检验有效性；进一步用 Conformalized Quantile Regression（CQR；Romano et al. 2019）做自适应宽度区间，并按 applicability domain（测试分子到最近训练分子的 Tanimoto 相似度）分层检验条件覆盖。

3 BACE 结果

3.1 活性预测基准

表征	策略	Pearson R $\uparrow$	MAE $\downarrow$
Chempop D-MPNN	策略二 · 图网络	0.835 $\pm$ 0.005	0.604
RF + Morgan	策略一 · 基线	0.804 $\pm$ 0.002	0.643
ChemFM-3B	策略一 · 大模型	0.803 $\pm$ 0.004	0.651
Uni-Mol (3D)	超纲 · 三维	0.800 $\pm$ 0.006	0.650
MolFormer-XL	策略一 · 序列	0.798 $\pm$ 0.037	0.657

（3 seed 均值 ± 标准差；pIC50 单位）。Chempop（图网络）在 Pearson R 与 MAE 上双双最佳（0.835 / 0.604），其余四类表征聚于 $R \approx 0.80$ ——BACE 的构效信号各类表征都能抓到；MolFormer 跨种子方差较大（ ± 0.037 ），如实呈现、不挑种子。阴性对照：打乱训练标签重训后 permuted Pearson R ≈ -0.06 （ ≈ 0 ），确认 0.835 是真实信号而非记忆噪声。

3.2 结构对接：位姿可信，打分不预测活性

我们先验证对接协议的几何可信度：将共晶配体 BXD 重新对接进受体，顶位姿与晶体构象的原位 RMSD 为 0.92 Å（优于 2 Å 的“成功重现”阈值，图 1），表明口袋盒子与受体准备能可靠重现已知结合模式。




图1 redock 验证：共晶 BXD（橙）与重对接顶位姿（绿）在 β -secretase 口袋内高度重合，原位 RMSD 0.92 Å

但对接打分预测活性的能力很弱。在重原子 [20,40] 的类药窗口内取 30 个跨活性配体，原始 Pearson(pIC₅₀, Vina) = -0.34 (n=30, p=0.069, 未达显著，图 2)。采用配体效率 (LE = Vina 打分 / 重原子数) 这一标准的尺寸归一化后，相关性进一步消失 (Pearson +0.10, p=0.59)：原本的弱相关主要由分子大小驱动，而非与尺寸无关的结合强度信号。




图2 BACE 配体 docking 打分 vs 实验 pIC₅₀（颜色为重原子数）；n=30，Pearson $r=-0.34$ 未达显著 ($p=0.069$)

因此对接的价值在于可解释的结合模式假设，而非活性排序。图 3 中一个高活性抑制剂 (pIC₅₀ 9.19) 占据催化口袋并与天冬氨酸残基形成氢键；而打分最强的配体 (Vina -10.5) 实测活性却接近最低 (pIC₅₀ 4.65)，直观印证“打分 $\neq$ 活性”。需补充：即便最优数据驱动模型在 BACE 上的 MAE $\approx$ 0.60 pIC₅₀ (约 4 倍 IC₅₀ 误差)，也仅够粗筛排序，不足以分辨先导优化所需的 2-3 倍活性差异。




图3 高活性抑制剂 (pIC₅₀ 9.19) 的对接结合模式：配体 (青) 位于 β -secretase 催化口袋，与天冬氨酸残基 (橙) 形成氢键 (红虚线)

3.3 Conformal 可信度：何时可以相信预测

点预测回答了“哪个骨架更准”，conformal 回答“何时可以相信它”。下表为 BACE 上各骨架的 split conformal 区间宽度与经验覆盖率（名义 0.90）。

表征	区间宽度 (pIC ₅₀) ↓	经验覆盖率 (名义 0.90)
ChemFM-3B	2.63	0.895 (略欠)
Chemprop	2.66	0.925
RF + Morgan	2.87	0.934
Uni-Mol (3D)	2.88	0.934
MolFormer-XL	2.93	0.924

BACE 上各骨架均达有效覆盖 (0.90–0.93)，Chemprop 给出最紧的合法区间，约 ± 1.33 pIC₅₀。但区间宽度提醒我们“有效不等于可用”： ± 1.3 pIC₅₀ $\approx$ 20 倍 IC₅₀，对前瞻性优先级排序的价值有限。条件覆盖审计更进一步——按到训练集的 Tanimoto 分层，低相似度（新骨架）子群系统性欠覆盖 (RF 0.87、ChemFM 0.82)，高相似度子群过覆盖 (0.94–0.97)；二者在边际上相互抵消，使总体覆盖“看起来”达标。这对需外推到新化学的虚拟筛选是直接的可信度警示。CQR 自适应区间在 BACE 上并不划算 (Chemprop 的 CQR 区间反而增宽至 6.74)，此处 split conformal 已足够。

4 扩展验证：6 个数据集

为检验上述方法学是否只在 BACE 成立，我们将同一流程扩展到全部 6 个 MoleculeNet 数据集（5 回归 + 1 分类）。这部分超出“单一任务”的课程要求，作为稳健性验证。

点预测上没有单一最优骨架：回归任务中图网络 (Chemprop) 与三维模型 (Uni-Mol) 总体领先（二者包揽 Pearson R 前二，ESOL / FreeSolv 上 Uni-Mol 达 0.97），BBBP 分类由序列 Transformer (MolFormer-XL，ROC-AUC 0.977) 领先，传统 RF + 指纹始终是极强的性价比基线，而 ChemFM-3B 的默认 LoRA 在小数据集失配 (GSHt Pearson R 仅 0.327)。图 4 给出 5 类骨架在 5 个回归任务上的 MAE 与 Pearson R。




图4 五类骨架在5个回归任务上的性能：上MAE（越低越好）、下Pearson R（越高越好）；误差棒为3 seed 标准差（验证集）

可信度上，跨基础模型的 conformal 横评量化了“最紧 $\neq$ 有效”：Uni-Mol 在多数任务区间最紧，却在 ESOL 欠覆盖至 0.83（图 5）——窄而不可信；§3.3 在 BACE 上观察到的“低相似度子群欠覆盖”在 6 数据集上普遍成立。诚实定位：“神经模型过度自信”“覆盖随相似度退化”这两个现象在 MUBen (TMLR 2024)、Norinder (2014) 等文献中已充分报道；本工作的增量是在统一协议下对现代基础模型做横向 conformal 比较并量化代价，而非声称发现这些现象。




图5 区间宽度 vs 覆盖率（每个分面一个数据集；阴影 = 欠覆盖 90% 名义）

作为额外的泛化压力测试，我们在外部 MoleculeACE 基准（30 个 ChEMBL 活性靶；属外部数据，仅作确认性分析、不计入课程 6 数据集）上确认：所有骨架在“活性悬崖”上误差都更高，与近期文献（CheMeleon 2026；SemiMol）一致——即基础模型并未真正攻克活性悬崖。

5 科研级可复现性审计

我们对自身结果执行主动审计并披露全部局限。

数据泄漏：数据集的预定义划分存在不同程度的训练-测试支架重叠。以核心任务 BACE 为例：RF + Morgan 基线在预定义切分（测试-训练 Murcko 骨架重叠 64%）的 Pearson R 为 0.843，改用骨架严格分离的 scaffold split（重叠 0%）后降至 0.778（MAE 0.55 → 0.65，3 seed），即约 0.065 R 的虚高来自训练-测试相似性——退化温和但确实存在，应在比较中披露。其余数据集中，GSHt 为共价同系列化合物、天然共享骨架（重叠 89%，属同系列设计而非可避免缺陷），BBBP 有 21 个完全重复的 SMILES。

阴性对照：将训练标签随机置换后重训，BACE 等回归任务 permuted Pearson R ≈ 0 ；GSHt 的置换 Pearson R 落在 $[-0.33, +0.20]$ ，因此 ChemFM-3B 在 GSHt 上 0.327 的相关性落在噪声区间内、不构成真实信号。

6 讨论与结论

本报告以 BACE-1 抑制活性预测为核心，完成了一条从数据、五类分子表征建模、三维结构对接到 conformal 可信度评估的完整药物设计流程。主要结论：

- 机器学习能可靠预测 BACE 活性——Chemprop（图网络）R = 0.835、MAE = 0.604 最佳；但 MAE ≈ 0.60 pIC₅₀（约 4 倍 IC₅₀）仅够粗筛，不足以分辨先导优化的 2–3 倍活性差异。
- 结构对接位姿几何可信（redock 0.92 Å），但 Vina 打分不预测活性（配体效率归一化后相关性归零），价值在可解释的结合模式假设，不夸大物理打分。
- Conformal 回答“何时可信”——BACE 有效覆盖下最紧区间约 ± 1.3 pIC₅₀；但新骨架（低相似度）系统性欠覆盖，虚拟筛选需警惕。
- 上述结论在全部 6 个数据集的交叉验证下稳健；贯穿全文的方法论基石，是对自身结果的彻底审计与诚实披露——阴性对照与泄漏检查“拆穿”了若干表面良好的数字。

局限：(1) 主基准（点预测）数字基于验证集，测试集仅在 conformal 一次性最终评估中使用；(2) 对接样本 n=30 统计力有限， $r=-0.34$ 未达显著；(3) 点预测中的 Uni-Mol 经 unimol-tools 训练、库内随机种子固定，实为单次测量；(4) MolFormer-XL / ChemFM-3B / Uni-Mol 为外部大规模语料预训练模型，其表征隐含课程数据集以外的化学知识——此属课程“策略一：编码器”的既定用法，并未向任务数据引入额外化合物。

数据与代码可用性

数据：本研究核心任务使用课程提供的 BACE 数据集，扩展验证使用其余 5 个 MoleculeNet 数据集（ESOL / FreeSolv / Lipophilicity / BBBP / GSHt）； β -secretase 晶体结构 PDB 4D8C 取自公开数据库 RCSB。代码与结果：五类表征建模、conformal / CQR、结构对接（含 redock 位姿验证与渲染）与可复现性审计的脚本及结果表存于项目仓库，并经统一入口一键复跑。面向期刊正式投稿时，应按 ACS 数据政策将代码与可公开数据存入带 DOI 的公共仓库（如 Zenodo / Hugging Face）。

参考文献

- [1] Wu Z, et al. MoleculeNet: A Benchmark for Molecular Machine Learning. Chem Sci, 2018.
- [2] Subramanian G, et al. Computational Modeling of β -secretase 1 (BACE-1) Inhibitors. JCI, 2016.

- [3] Ross J, et al. Large-scale chemical language representations (MolFormer). Nat Mach Intell, 2022.
- [4] Zhou G, et al. Uni-Mol: A Universal 3D Molecular Representation Learning Framework. ICLR, 2023.
- [5] Heid E, et al. Chemprop: Machine Learning Package for Molecular Property Prediction (v2). JCIM, 2025.
- [6] Cai F, et al. ChemFM: A Foundation Model for Chemistry. 2024.
- [7] Trott O, Olson AJ. AutoDock Vina. J Comput Chem, 2010.
- [8] Eberhardt J, et al. AutoDock Vina 1.2.0 / Meeko ligand preparation. JCIM, 2021.
- [9] Li Y, et al. MUBen: Benchmarking the Uncertainty of Molecular Representation Models. TMLR, 2024.
- [10] Norinder U, et al. Conformal Prediction to Define Applicability Domain. JCIM, 2014.
- [11] Romano Y, Patterson E, Candès EJ. Conformalized Quantile Regression. NeurIPS, 2019.
- [12] van Tilborg D, et al. Exposing the Limitations of Molecular ML with Activity Cliffs (MoleculeACE). JCIM, 2022.