

BACE-1 抑制剂活性预测 — 课堂汇报演讲稿（专业版）

汤雨凡（学号 23307130372）· 复旦大学药学院《AI 赋能药物设计发现前沿》· 约 13 分钟 / 14 页

面向同行的技术稿。Morgan 指纹为半径 2、2048 维（与 PPT、报告一致）。

第 1 页 · 标题（开场，~25 秒）

各位老师好。本工作以 MoleculeNet 的 BACE 数据集、1513 个化合物的 pIC50 回归为单一任务，系统比较覆盖两类建模范式的四种分子表征，并补充 conformal 不确定性量化，全流程附可复现性审计。约十二分钟。

第 2 页 · §1 背景与选题（~50 秒）

BACE-1，即 β -分泌酶 1，是一种天冬氨酸蛋白酶，在 β 位点切割淀粉样前体蛋白 APP、启动 A β 生成与斑块沉积，是阿尔茨海默病的已验证靶点。本任务在 1513 个化合物上回归其对 BACE-1 的 pIC50，指标以 Pearson 相关系数与 MAE 为主、辅以 RMSE 与 Spearman。选 BACE 作单一任务，是因为它是阿尔茨海默病的真实药物靶点、活性数据完整，且能同时容纳两类建模范式做对照，支撑严格的可信度评估与可复现性审计。

第 3 页 · §1 数据概览（~90 秒）

先做化学空间表征。1513 个化合物的类药描述符中位数：分子量 464、重原子数 33、计算脂水分配系数 cLogP 3.1、拓扑极性表面积 TPSA 91、环数 4、可旋转键数 7，整体落在类药区间；其中 TPSA 中位数 91 接近中枢神经系统药物入脑的经验阈值（约 90），与 BACE-1 作为脑内靶点一致。响应变量 pIC50 跨约八个对数单位（2.54 至 10.52）、近正态、均值 6.52；训练 / 验证 / 测试为数据集预定义划分 1059 / 151 / 303，三子集描述符分布基本重合。正因标签跨度大，后续同时报告相关性与误差两类指标，避免单一指标误导。

第 4 页 · §2 数据与方法（~85 秒）

四种表征覆盖两类范式。

策略一（SMILES / 指纹 $\rightarrow$ 编码器 $\rightarrow$ 机器学习）：

- **RF + Morgan**——用 Morgan (ECFP) 圆形指纹、半径 2、折叠成 2048 维 0/1 位向量表征分子，再输入随机森林做回归（500 棵树、不限深度）。
- **MolFormer-XL**——IBM 的序列 Transformer，约 4400 万参数，采用线性注意力与旋转位置编码，在 11 亿 PubChem 与 ZINC 的 SMILES 上做掩码语言建模预训练，本项目全参数微调。
- **ChemFM-3B**——Llama 架构的 decoder-only 模型，30 亿参数，在 1.78 亿分子上以因果语言建模预训练，本项目用 LoRA 微调。

策略二（二维分子图 $\rightarrow$ 图神经网络）：

- **Chemprop**——有向消息传递网络 D-MPNN，在化学键（有向边）而非原子节点上传递消息、深度 3、隐藏维 300，均值聚合后接前馈网络。

第 5 页 · §2 训练流程（~85 秒）

以 MolFormer 为例说明管线：SMILES 经分词器编码为定长 128 的 token id 序列，过主干取末层隐状态，用 attention-mask 加权的均值池化 (masked-mean) 汇聚为 768 维分子表示，再接两层 MLP 回归头输出 pIC50。损失为均方误差，优化器 AdamW 配单周期学习率调度 OneCycleLR，梯度裁剪 1.0，以验证集最优做模型选择。

关于 **LoRA**（低秩适配）：ChemFM 有 30 亿参数，在约一千五百样本上全参数微调既不可行（显存与优化器状态过大）、又必然过拟合。LoRA 的做法是冻结预训练权重 $\mathbf{W}$ ，在注意力的 **query**、**value** 投影矩阵旁注入一个可训练的低秩增量 $\Delta\mathbf{W} = \mathbf{B} \cdot \mathbf{A}$ （秩 $r = 16$ ），前向输出为 $(\mathbf{W} + \mathbf{B}\mathbf{A})\mathbf{x}$ ，只训练 $\mathbf{A}$ 、 $\mathbf{B}$ 两个小矩阵——可训练参数仅约总量的 0.2%（610 万 / 30 亿）；主干用 bf16、回归头保持 fp32，并开梯度检查点省显存。所有随机

性由统一接口固定（覆盖 Python / NumPy / PyTorch / CUDA 与 cuDNN 确定性），测试集仅在最终 conformal 评估时使用一次。

第 6 页 · §2 训练收敛性验证（~90 秒）

逐模型给出验证表现随训练预算的轨迹：实线为验证、淡虚线为训练损失（右轴）、阴影为三种子带、星号为所选权重。随机森林无 epoch 概念，横轴取树的数量——验证 RMSE 从 10 棵的 0.845 到约 50 棵即进入平台，500 棵为冗余量。MolFormer 的三种子带最宽、波动最大，约第 24 个 epoch 取得验证最优，这一高方差正对应它后面最大的跨种子标准差。ChemFM 单调下降、约第 8 个 epoch 进入干净平台，即便只训 0.2% 参数。Chemprop 验证损失平稳下降、约第 38 个 epoch 触底，生产所用的第 50 个 epoch 与最优相差不足 5×10^{-3} ，可排除过拟合到末轮。多数面板可见训练损失继续下降而验证走平，即轻微过拟合，正由 best-on-validation 选择规避。右下为归一化收敛曲线，用于横向比较收敛速度。

第 7 页 · §3 活性预测（~50 秒）

Chemprop 在两项指标上均最优：Pearson 0.835、MAE 0.604（三种子均值）。其余三种聚集在 Pearson 约 0.80，包含 30 亿参数的 ChemFM。这表明在约一千五百样本规模下，二维图的归纳偏置优于参数量更大的序列预训练模型——参数规模并不等同于性能。MolFormer 跨种子方差较大 (± 0.037)，如实报告、未择优。

第 8 页 · §3 预测 vs 实测（~35 秒）

测试集 303 个分子的预测对实测散点，Chemprop 沿对角线最集中。四种模型共有的现象是低活性端的均值回归，源于低活性样本稀疏、信息量不足，属预期范围。

第 9 页 · §3 可信度（~65 秒）

点预测之外需要可信度边界。采用 split conformal：在校准集上以绝对残差为非一致性分数，取其 $(1 - \alpha)$ 分位数作为区间半宽，得到分布无关、有限样本下覆盖率有保证的预测区间，名义覆盖 90%。结果上，ChemFM 区间最窄 (2.63) 但经验覆盖仅 0.895、低于名义、不成立；Chemprop 在 2.66 处覆盖 0.925，是最窄的合法区间，约 ± 1.33 。但有效不等于可用： ± 1.33 约对应 20 倍 IC₅₀。进一步按 applicability domain 分层——以测试分子到最近训练分子的 Tanimoto 相似度分档——低相似度（新骨架）子群系统性欠覆盖（RF 0.87、ChemFM 0.82），对需外推到新化学空间的虚拟筛选是直接的可信度警示。

第 10 页 · §4 可复现性审计（~50 秒）

对自身结果做可复现性审计。预定义划分存在训练-测试相似性泄漏：Murcko 骨架重叠 64%、29% 的测试分子到训练集最近邻 Tanimoto 大于 0.85。改用骨架严格分离的 scaffold split 后，RF 的 Pearson 由 0.843 降至 0.778，约 0.065 的虚高来自相似性而非真实泛化，予以披露。此外约 71% 分子立体中心未定义，stereo-aware 模型存在性能虚高风险。

第 11 页 · §4 审计图证（~40 秒）

左为骨架重切的泄漏压力测试。右为阴性对照：将训练标签随机置换后重训十次，permuted Pearson 约 -0.06、近于零，排除模型记忆噪声的可能，反证 0.835 为真实构效信号。两者构成审稿级别的自检。

第 12 页 · §5 讨论与结论（~45 秒）

三点结论：第一，数据驱动模型可有效预测 BACE-1 活性，以 Chemprop 最优，但 MAE 约 0.6 仅支持粗筛、不足以分辨先导优化所需的细微差异；第二，conformal 给出了预测的可信边界，对全新骨架需警惕；第三，贯穿全程的方法论基石是对自身结果的彻底审计与诚实披露。

第 13 页 · 谢谢大家（~10 秒）

以上即从数据、四类表征到可信度评估的完整工作。感谢戚逸飞老师与王任小老师，欢迎提问。

必背数字：0.835 / 0.604 (Chemprop) · 0.843 $\rightarrow$ 0.778 (scaffold split) · -0.06 (阴性对照) · 0.895 < 0.90 (ChemFM 欠覆盖)