

《BACE-1 抑制剂活性预测》课堂汇报·演讲者讲稿

汤雨凡 (学号 23307130372)·复旦大学药学院《AI 赋能药物设计发现前沿》·全程约 13 分钟·14 页

第 1 页 BACE-1 抑制剂活性预测

(开场 30s)

各位老师好，我是汤雨凡，学号 23307130372，汇报《BACE-1 抑制剂活性预测》。课程六选一，我没有六个都浅尝，而是只选 BACE-1 一个、把它做透——从数据、四种建模、三维对接，一直做到“预测什么时候能信”，并且全程自己审计自己的结果。下面约十二分钟讲清这条完整链路。

第 2 页 为什么选 BACE-1 作为单一任务

§1 背景与选题 (50s)

为什么选它：BACE-1 是阿尔茨海默病里的一把“坏剪刀”——切割 APP、生成 A β 斑块，抑制它有望阻断斑块。我选单一任务是有意：作业要的是把一个任务做完整，而 BACE 是六个候选里唯一能把课程知识点串成一条龙的——既能比两种建模策略，又有公开晶体结构能做对接，正中结构计算。我特意没有铺六个数据集的横向对比，因为那超出“单一任务”的范围，只会冲淡深度。

第 3 页 BACE 化学空间一览 (1513 个分子)

§1 数据概览 (45s)

这是数据的化学空间。1513 个分子，活性 pIC₅₀ 横跨约 8 个对数单位、近正态，平均 6.5；分子量、cLogP、极性表面积都落在类药区间。我先看分布再建模，是因为标签跨 8 个量级会影响 RMSE 的解读，所以后面我同时报 Pearson R 和 MAE，而不是只挑一个好看的。这是真实合理的药化数据集，不是玩具数据。

第 4 页 四类分子表征 + 结构对接流程

§2 数据与方法 (70s·主线)

先用一句大白话讲清“分子表征”：电脑只认数字、不认分子，所以得先把分子翻译成一串数字——怎么翻译，就是“表征”。同一个分子有两种看法：当成一句话（文字 SMILES）、当成一张关系网（二维图）；这四个模型就是这两种看法的代表。

策略一·当文字读：RF+Morgan、MolFormer、ChemFM；策略二·当关系网读：Chemprop。我这么设计，是为了回答一个问题：到底“更聪明的表征”重要，还是“更大的模型”重要？对接这边：4D8C 取受体、共晶配体定盒子、AutoDock Vina 对接。

【若被追问“这四个到底是什么”——大白话版，逐个秒答】

· RF+Morgan：给分子做一张“体检勾选表”（含苯环?√ 含羟基?×），再让一群决策树投票。最朴素的及格线，没有预训练。

· MolFormer-XL：读分子的 ChatGPT——预读了 11 亿个分子、练出“化学语感”。

· ChemFM-3B：更大的同款（30 亿参数）；太大全身调不动，用 LoRA 只贴一张“BACE 便利贴”、只训 0.2% 参数。

· Chemprop (图网络): 把分子当朋友圈, 相邻原子互相“传八卦”, 传几轮就读懂整张分子图。我项目里最准 ($R=0.835$)。

收尾一句: 让“当文字 / 当图”两种看法同台比, 结果“当图看”的 Chemprop 赢了——说明在这点数据上, 聪明的表征比更大的模型更值钱。

【预训练权重来源】MolFormer-XL 的权重来自 IBM Research——HuggingFace 上的 `ibm-research/MolFormer-XL-both-10pct`, 在约 11 亿个 PubChem + ZINC 分子上预训练; ChemFM-3B 来自美国 Clemson 大学罗锋 (Feng Luo) 团队——HuggingFace 上的 `ChemFM/ChemFM-3B`, 在约 1.78 亿个分子 (UniChem 库) 上预训练。RF + Morgan 和 Chemprop 没有预训练权重, 都是在 BACE 这 1513 个分子上从零训练的。

第 5 页 训练循环 (以 MolFormer-XL 为例)

§ 2 训练流程 (75s)

这页放真实代码, 想让老师看到我清楚每一步在做什么、不是调个库就完事。以 MolFormer 为例: SMILES 先被分词器编码成定长 128 的整数张量, 送进主干得到每个 token 的向量, 再用 attention-mask 加权做平均池化、压成一个 768 维分子指纹, 过两层 MLP 输出 pIC50。主循环是标准五步: 清梯度、前向、算 MSE、反传、梯度裁剪后更新, 配 OneCycleLR。三条纪律: 小模型全参微调够用、ChemFM 用 LoRA 只训 0.2% 参数; 每个 epoch 末在验证集挑最优权重; 所有随机性用 `set_all_seeds` 锁死, 可复现。

【超参怎么定的——若被追问】我有意没做系统的超参搜索, 而是给每个模型用它发表时的默认配方: RF 取 500 棵树、MolFormer 用 IBM 原文的微调配方、ChemFM 用通用的低秩适配默认、Chemprop 用官方默认。两个理由: 一是跨模型比较用各自默认配方才公平 (否则把一个调爆、另一个用默认就有偏); 二是验证集只有 151 个分子, 大力搜超参容易把它过拟合、反而是隐性泄漏。唯一基于数据的调整是 best-on-val 选最优轮次 + 三种种子平均, 且只用验证集、测试集只看一次。绝对数字若做搜索可能再涨, 但公平比较下的结论是稳的——这点我作为局限如实披露。

第 6 页 四类表征在 BACE 上都训练到平台

§ 2 训练收敛性验证 (55s)

老师一定会问: 你怎么知道模型训练充分了? 这页就是答案。四种表征在验证集上的逐 epoch 曲线, 阴影是三个种子的波动。全部收敛到平台: ChemFM 八个 epoch 就到位; MolFormer 抖动最大——恰好解释了它后面种子方差最大; Chemprop 第 50 个 epoch 正好落在平台上、和最优只差 0.005, 说明没有过拟合到末轮。一句话: 我报的每个数字都来自训练充分、收敛之后的模型。

第 7 页 回归基准: 图网络 (策略二) 领先

§ 3 BACE 结果 · 活性预测 (55s)

核心结果: 图网络 Chemprop 双指标最佳, Pearson R 0.835、MAE 0.604。有意思的是其余四种都聚在 $R \approx 0.80$ ——包括最大的 ChemFM。这说明在这个数据规模上, 把分子当“图”来学, 比“更大的语言模型”更对路; 模型越大不等于越好。我也如实报告 MolFormer 跨种子方差较大 (± 0.037), 没有挑最好那一次。

第 8 页 预测 vs 实测: 四类表征同台 (测试集 $n=303$)

§ 3 BACE 结果 · 活性预测 (40s)

换成散点更直观, Chemprop 沿对角线最紧凑。请注意一个所有模型的共性: 弱活性那一端, 预测都略微往均值收。这不是 bug, 是低活性样本本来就稀疏、难预测的必然结果——我在讨论里也明确写了。

第 9 页 位姿几何可信, 但打分不预测活性

§ 3 BACE 结果 · 结构对接 (70s, 最关键, 稳住)

先验证可信度: 把已知结合的共晶配体重新对接回去, 和晶体姿势只差 0.92 埃, 远好于 2 埃成功线——几何可信。但我必须诚实: 对接打分几乎不能预测活性。原始相关只有 -0.34、不显著; 而且大分子天生容易拿高分, 用配体效率按分子大小归一后, 相关性归零到 +0.10。所以对接价值在于可解释的结合模式假设, 不是给活性排序。

【用王任小老师的 CASF 框架, 显得懂行】我的结果可以用王老师 CASF 的“四种能力”来定位: redock 0.92 Å = docking power 好 (能挑对位姿); 打分不预测活性 = scoring / ranking power 弱。这恰好印证 CASF-2016 的总体结论——打分函数擅长摆姿势、不擅长评活性。配体效率归一化, 本质是修正经验打分函数“分子越大、原始分越高”的已知偏差, 去掉分子大小这个混杂因素。

【若被追问“对接是不是白做了”】不是。它给的是可解释的结合模式——配体怎么卡进催化口袋、和哪个天冬氨酸形成氢键, 对理解机制有用; 我只是不拿它的分数去排活性。这也正是我整个项目“ML 预测活性 + 对接解释机理”分工的合理性来源。

第 10 页 何时可以相信预测? Conformal 区间

§ 3 BACE 结果 · 可信度 (60s)

光预测一个数还不够, 得知道什么时候能信它。我用 conformal 给出带 90% 保证的预测区间。BACE 上各模型都达到有效覆盖, Chemprop 最紧的合法区间约 ± 1.3 。但“有效不等于可用”: ± 1.3 换算成活性差不多是 20 倍, 对精细排序帮助有限。更重要的是分层审计: 对训练时没见过的新骨架, 区间会偏乐观、欠覆盖——这是给虚拟筛选的直接警示, 不是漂亮话。

第 11 页 拆穿自己的数字: BACE 的诚实披露

§ 4 科研级可复现性审计 (50s)

这页是我最想强调的——我主动拆自己的台。预定义划分有 64% 的骨架重叠, 意味着部分成绩来自“见过相似的分子”。我改用严格的骨架分离重测, R 从 0.843 掉到 0.778。这 0.065 的虚高, 我如实写出来、不藏。诚实披露本身就是这份作业的方法论亮点。

第 12 页 泄漏压力测试 + 阴性对照

§ 4 可复现性审计 · 图证 (45s)

左图就是刚才的泄漏压力测试。右图是阴性对照: 我把训练标签随机打乱重训——如果模型还能预测准, 说明它在背噪声; 结果 $R \approx -0.06$ 、几乎是零。这就证明 0.835 是真实的构效关系, 不是记忆。这两步是审稿人级别的自查。

第 13 页 结论

§ 5 讨论与结论 (50s)

总结四点: 一, 机器学习能可靠预测 BACE 活性, 图网络最好, 但精度只够粗筛、不够先导精修; 二, 对接位姿可信、打分不预测活性, 我诚实定位了它的价值; 三, conformal 回答了“何时可信”, 新骨

架要警惕；四，也是贯穿全程的基石——对自己结果的彻底审计与诚实披露。感谢戚逸飞老师和王任小老师的指导，欢迎提问。

第 14 页 谢谢大家

(50s)

总结四点：一，机器学习能可靠预测 BACE 活性，图网络最好，但精度只够粗筛、不够先导精修；二，对接位姿可信、打分不预测活性，我诚实定位了它的价值；三，conformal 回答了“何时可信”，新骨架要警惕；四，也是贯穿全程的基石——对自己结果的彻底审计与诚实披露。感谢戚逸飞老师和王任小老师的指导，欢迎提问。
