

基于五类分子表征的 ADMET 性质预测、 结构对接与可信度评估

复旦大学药学院《AI 赋能药物设计发现前沿》期末实验报告

姓名/学号: _____

授课教师: 戚逸飞 / 王任小

算力: $8 \times$ NVIDIA RTX 5880 Ada (48GB)

日期: 2026 年 6 月

目录

摘要

成药性质（ADMET）的早期预测是现代药物发现的关键环节。本报告在教师提供的 6 个 MoleculeNet 数据集（5 回归 + 1 分类）上，系统比较课程介绍的两种建模策略：策略一（SMILES → 编码器 → 机器学习）与策略二（SMILES → 二维分子图 → 图神经网络），并补充一个超纲的三维几何模型。五类分子表征骨架为：随机森林 + Morgan 指纹、MolFormer-XL、ChemFM-3B、Chemprop D-MPNN（图网络）、Uni-Mol（3D）。

在回归任务上，图网络（Chemprop）与三维几何模型（Uni-Mol）总体领先于指纹/序列方法：二者包揽 Pearson R 前二，Chemprop 在 BACE 上最高（0.835）；BBBP 分类则以序列模型 MolFormer-XL 最强（ROC-AUC 0.977）。我们进一步将 BACE 配体对接进 β -secretase 晶体结构（共晶配体 redock RMSD 0.92 Å 验证位姿几何，但打分不预测活性），并贯彻一套科研级可复现性审计（泄漏检查、阴性对照、配体效率归一化），主动披露全部局限。方法学主线上，我们给出跨基础模型的 conformal 预测可信度评估，量化“最紧 $\neq$ 有效”——Uni-Mol 区间最紧却在 ESOL 欠覆盖至 0.83。

1 引言

当代新药研发平均耗时 10 年以上、花费超 10 亿美元；每 1 万个进入研究的化合物中，最终仅约 1 个上市。在早期高效淘汰成药性质差的候选物，是降低研发成本的核心策略，而 ADMET（吸收、分布、代谢、排泄、毒性）预测正是这一环节的关键计算工具。

本课程作业要求：选择课程介绍的某项人工智能药物设计预测任务，完成数据整理、模型构建、训练与分析，并撰写书面报告。课程给出两种建模策略：策略一基于 SMILES 字符串编码 + 机器学习；策略二基于二维分子图的图神经网络。本报告以 BACE-1 (β -secretase) 抑制剂活性预测为核心任务——它能把数据清洗、两种建模策略、三维表征、结构对接与可信度评估串成一条完整流程；并在此基础上将同一套方法学扩展到全部 6 个数据集做交叉验证、补充方法学探索，力求覆盖课程全部知识点。

2 数据与任务设定

课程提供 6 个 MoleculeNet 数据集，任务类型与评价指标如下表（均为教师钦定）。

任务	预测性质	分子数	类别	指标
ESOL	水溶性 logS	1128	回归	MAE / Pearson R
FreeSolv	水合自由能 ΔG	642	回归	MAE / Pearson R

任务	预测性质	分子数	类别	指标
Lipophilicity	脂溶性 logD@7.4	4200	回归	MAE / Pearson R
BACE	β -secretase IC50	1513	回归	MAE / Pearson R
BBBP	血脑屏障渗透	2039	分类	ROC-AUC
GSHt1/2	共价反应性	419	回归	MAE / Pearson R

数据纪律：所有 SMILES 经 RDKit canonical 化一次；解析失败的分子记录数量后剔除（不静默丢弃）；任何标准化仅在训练折上拟合，防止信息泄漏。

3 方法

3.1 两种建模策略与五类表征

我们覆盖课程的两种策略，并各取代表模型；额外加入一个三维几何模型作为超纲对照：

- **策略一（SMILES → 编码器 → ML）：**随机森林 + Morgan 指纹（radius 2, 2048 位）；MolFormer-XL（11 亿分子预训练的序列 Transformer，47M 参数）；ChemFM-3B（30 亿参数解码器大模型，LoRA 微调）。
- **策略二（SMILES → 二维图 → GNN）：**Chemprop D-MPNN——有向键消息传递网络，在原子（节点）+ 键（边）特征上做图学习。
- **超纲（三维几何）：**Uni-Mol，SE(3)-Transformer，显式利用 RDKit ETKDGv3 生成的 3D 构象。

3.2 评估协议

每个（数据集 × 模型）组合跑 3 个随机种子（42 / 1337 / 2024）取均值 ± 标准差。回归报告 MAE 与 Pearson R（课程指标），分类报告 ROC-AUC；并辅以 RMSE / Spearman ρ / F1 / MCC。回归目标在训练折上 z 标准化（防泄漏），评估时还原到原单位。

3.3 结构对接模块

从 PDB 4D8C 提取 β -secretase A 链，用 Meeko 准备受体，以共晶配体 BXD 定义口袋盒子（中心 30.58, 6.24, 14.52；尺寸 22×22×26 Å）。BACE 配体经 RDKit 3D 嵌入 + Meeko 转 PDBQT，用 AutoDock Vina 对接，对比 docking 打分与实验 pIC50。对接前先以共晶配体 BXD 重对接，验证协议能否重现晶体结合模式（结果见 §4.4）。

4 结果

4.1 回归基准 (Pearson R / MAE)

数据集	RF	Chemprop	MolFormer	ChemFM	Uni-Mol
ESOL	0.807	0.953	0.900	0.769	0.966
FreeSolv	0.896	0.937	0.833	0.679	0.967
Lipophilicity	0.695	0.875	0.860	0.756	0.875
BACE	0.804	0.835	0.798	0.803	0.800
GSht	0.722	0.648	0.545	0.327	0.749

表中为 Pearson R (越高越好, 3 seed 均值)。下图同时给出 MAE 与 Pearson R 两个面板。




图1 五类骨架在 5 个回归任务上的性能: 上 MAE (越低越好)、下 Pearson R (越高越好); 误差棒为 3 seed 标准差 (验证集)

4.2 分类基准 (BBBP)

RF	Chemprop	MolFormer	ChemFM	Uni-Mol
0.926	0.899	0.977	0.971	0.891

表中为 ROC-AUC (3 seed 均值)。下图同时报告四项分类指标——MCC 才暴露真实差距：ROC-AUC / PR-AUC / F1 都在 0.9 附近难分高下，但 MCC 上 MolFormer 与 ChemFM (约 0.80) 比 RF / Chemprop / Uni-Mol (约 0.65) 高出约 0.15。这正是单一指标会掩盖、必须四指标并报的原因。




图 2 BBBP 分类四指标 (ROC-AUC / PR-AUC / F1 / MCC) ; 误差棒为 3 seed 标准差 (验证集)

4.3 策略一 vs 策略二

核心结论是没有单一最优骨架，最佳表征取决于任务性质与数据规模。回归任务上，图网络（策略二，Chemprop）与三维几何模型（Uni-Mol）总体领先于指纹/序列方法（策略一）：二者包揽 Pearson R 前二，Chemprop 在 BACE 上达全场最高 0.835、MAE 一致优于随机森林。ChemFM-3B 因 LoRA 微调在小数据集失配而最弱（GSHt Pearson R 仅 0.327）。BBBP 分类则由序列 Transformer（MolFormer-XL）领先。

4.4 BACE 结构对接

我们先验证对接协议的几何可信度：将共晶配体 BXD 重新对接进受体，顶位姿与晶体构象的原位 RMSD 为 0.92 Å（优于 2 Å 的“成功重现”阈值，图 3b），表明口袋盒子与受体准备能可靠重现已知结合模式。




图 3b redock 验证: 共晶 BXD (橙) 与重对接顶位姿 (绿) 在 β -secretase 口袋内高度重合, 原位 RMSD 0.92 Å

但对接打分预测活性的能力很弱。在重原子 [20,40] 的类药窗口内取 30 个跨活性配体, 原始 $\text{Pearson}(\text{pIC}_{50}, \text{Vina}) = -0.34$ ($n=30$, $p=0.069$, 未达显著, 图 3)。采用配体效率 ($\text{LE} = \text{Vina 打分} / \text{重原子数}$) 这一标准的尺寸归一化后, 相关性进一步消失 ($\text{Pearson} +0.10$, $p=0.59$): 原本的弱相关主要由分子大小驱动, 而非与尺寸无关的结合强度信号。




图 3 BACE 配体 docking 打分 vs 实验 pIC_{50} (颜色为重原子数); $n=30$, $\text{Pearson } r=-0.34$ 未达显著 ($p=0.069$)

因此对接的价值在于可解释的结合模式假设, 而非活性排序。图 3c 中一个高活性抑制剂 (pIC_{50} 9.19) 占据催化口袋并与天冬氨酸残基形成氢键; 而打分最强的配体 (Vina -10.5) 实测活性却接近最

低 (pIC_{50} 4.65)，直观印证“打分 $\neq$ 活性”。需补充：即便最优数据驱动模型在 BACE 上的 MAE ≈ 0.60 pIC_{50} （约 4 倍 IC_{50} 误差），也仅够粗筛排序，不足以分辨先导优化所需的 2–3 倍活性差异。




图 3c 高活性抑制剂 (pIC_{50} 9.19) 的对接结合模式：配体（青）位于 β -secretase 催化口袋，与天冬氨酸残基（橙）形成氢键（红虚线）

4.5 稳健性补充：活性悬崖压力测试

基础模型并未真正攻克活性悬崖。作为泛化能力的额外压力测试，我们在 MoleculeACE 基准（30 个 ChEMBL 活性靶；外部数据，仅作确认性分析，不计入课程 6 数据集）上，比较各骨架在“活性悬崖”（结构相似但活性悬殊的分子对）与非悬崖样本上的 RMSE。所有骨架在悬崖上误差都更高（cliff ratio > 1 ），三维 Uni-Mol 受影响最重（中位 1.25，97% 的靶 > 1 ），序列 MolFormer 最轻（1.04），与近期文献（CheMeleon 2026；SemiMol）一致。我们确认该现象，但不作为主要贡献。




图4 活性悬崖压力测试 (MoleculeACE, 30 靶): 左为各靶 off- vs on-cliff RMSE (对角线上方 = 悬崖更差), 右为 cliff ratio 分布 (> 1 = 受悬崖惩罚)

5 科研级可复现性审计

我们对自身结果执行主动审计并披露全部局限。

数据泄漏: 6 个数据集的预定义划分均存在不同程度的训练-测试支架重叠。GSHt 为共价同系列化合物, 天然共享 Murcko 骨架, 使重叠高达 89% (419 个分子仅 140 个不同骨架、最大单一骨架占 24%——属同系列设计, 而非可避免的切分缺陷); BBBP 有 21 个完全重复的 SMILES。我们进一步量化了泄漏对性能的实际影响: 在 BACE 上, RF + Morgan 基线在预定义切分 (测试-训练骨架重叠 64%) 的 Pearson R 为 0.843, 改用骨架严格分离的 scaffold split (重叠 0%) 后降至 0.778 (MAE 0.55 → 0.65, 3 seed), 即约 0.065 R 的虚高来自训练-测试相似性——退化温和但确实存在, 应在跨方法比较中披露。

阴性对照: 将训练标签随机置换后重训, 5/6 数据集通过 (回归 Pearson R $\approx$ 0); 但 BBBP 因类别不平衡, 置换标签 ROC-AUC 仍达 0.558 (而非 0.5), GSHt 的置换 Pearson R 范围 [-0.33, +0.20]——因此 ChemFM-3B 在 GSHt 上 0.327 的相关性落在噪声区间内, 不构成真实信号。

6 方法学探索: 基础模型的 Conformal 预测可信度

点预测基准回答了“哪个骨架更准”, 却没回答“何时可以相信它”。Conformal prediction 提供分布无关、有限样本的覆盖率保证, 使我们能问一个更实用的问题: 哪个骨架在保持有效覆盖 (经验覆盖率 $\geq$ 名义 90%) 的前提下给出最紧的预测区间? 这是本报告的方法学主线。

诚实定位：“conformal 覆盖随化学相似度下降而退化”、“神经模型过度自信”这两个现象，在 conformal-QSAR 与不确定性文献中均已充分报道（Norinder 2014；MUBen TMLR 2024；CoDrug NeurIPS 2023；Hosni ACS Omega 2026 等）。本节并非声称发现这些现象，而是在统一协议下首次对现代基础模型（MolFormer-XL / Uni-Mol-3D / ChemFM-3B / RF-Morgan / Chemprop）做横向 conformal 比较，并量化“最紧 $\neq$ 有效”的代价。

6.1 覆盖率总览

图 5 是 5 骨架 $\times$ 5 回归任务在 90% 名义覆盖下的经验覆盖率热图。多数格点接近 0.90（标定良好），但 Uni-Mol 在 ESOL（0.83）与 Lipophilicity（0.87）两格明显欠覆盖（红色），GSHt 行整体过覆盖（蓝色， $\approx 0.98\text{--}1.00$ ）。




图5 各骨架 $\times$ 数据集的经验覆盖率（名义 0.90；红 = 欠覆盖、蓝 = 过覆盖）

6.2 最紧 $\neq$ 有效

将区间宽度与覆盖率并置（图 6）可见：Uni-Mol 在多数任务上给出最窄区间，但其 ESOL 区间虽最紧、覆盖率却跌进阴影“欠覆盖”区——窄而不可信。图 7 的宽度排行榜对此以斜纹标注：覆盖率未达标的骨架，其“最紧”不计入有效排名。在覆盖有效的任务上，Uni-Mol 与 Chemprop 通常给出最紧的合法区间。但需提醒：有效不等于可用——以 BACE 为例，最紧的合法区间约为 ± 1.3 pIC50 (≈ 20 倍 IC50)，对前瞻性优先级排序的价值仍然有限。




图6 宽度 vs 覆盖率 (每个分面一个数据集; 阴影 = 欠覆盖 90% 名义)




图7 区间宽度排行榜 (斜纹 = 覆盖率未达标, 宽度不可比)

6.3 条件覆盖：边际达标掩盖了 OOD 失效

边际覆盖达标不代表处处可信。按 applicability domain (测试分子到最近训练分子的 Tanimoto 相似度) 分层后 (图 8)，所有骨架在低相似度 (新化学, $T \approx 0.46$) 子群系统性欠覆盖、在高相似度子群过覆盖——二者相互抵消, 使边际覆盖“看起来”达标。这对真实虚拟筛选 (常需外推到新骨架) 是直接的可信度警示, 也是本节相对边际指标的增量。




图8 按 applicability domain 分层的条件覆盖率：低相似度子群全骨架欠覆盖

6.4 自适应区间：CQR 能否补回欠覆盖？

固定宽度的 split conformal 无法刻画异方差误差。我们进一步为每个骨架训练分位回归头（pinball 损失预测 5%/95% 分位），再用 Conformalized Quantile Regression（CQR；Romano et al. 2019）做有限样本校正，得到自适应宽度区间。结果（图 9）呈骨架依赖：

- Uni-Mol：在其欠覆盖的 ESOL 上，CQR 把覆盖率从 0.83 修复到 0.90（自适应加宽）；在过覆盖的 GSHt 上反而收紧区间——CQR 对这个三维、异方差骨架最有价值。
- 经典 / 图网络（GBM、Chemprop）：小数据上分位头噪声大，CQR 区间普遍变宽、并不优于固定宽度——“自适应”在样本不足时未必划算。

即 CQR 的价值取决于骨架与误差结构，而非普适改进。这是一个诚实的负-正混合结论，而非“CQR 全面更优”的夸大。




图9 split conformal $\rightarrow$ CQR: 左为覆盖率 (对角线上方 = CQR 改善, Uni-Mol/ESOL 越过 0.90), 右为宽度 (对角线下方 = CQR 更紧)

6.5 分类校准: 温度缩放

对分类, 可信度对应概率校准。BBBP 上的 Morgan-MLP 高度过度自信 (约 93% 的预测把置信度堆在 ≈ 1.0 、却仅 87% 正确)。单参数温度缩放 ($T \approx 5.0$) 将期望校准误差 ECE 从 0.130 降到 0.070 (-46%), 如图 10 中主簇 (标记面积 $\propto$ 样本数) 向对角线移动所示。




图 10 BBBP 可靠性图 (温度缩放前后; 标记面积 $\propto$ 该置信度区间样本数; ECE 降低 46%)

7 讨论

模型选型启示: (1) 对小型理化/活性数据集, 图网络与三维表征优势明显, 但传统 RF + 指纹仍是极强的性价比基线; (2) 大语言模型 (ChemFM-3B) 的默认 LoRA 配置在小数据集上失效, 提示实用部署需谨慎调参; (3) 结构对接位姿几何可信 (共晶 redock RMSD 0.92 Å), 但 Vina 打分不能定量预测活性 (配体效率归一化后相关性归零), 价值在结合模式假设而非活性排序。

可信度的实用启示: 最准的骨架未必最可信——Uni-Mol 点预测最强、conformal 区间最紧, 却在 ESOL / Lipophilicity 欠覆盖; 自适应 CQR 能修复特定骨架的欠覆盖却非普适; 所有骨架在低相似度子群条件欠覆盖。因此实际部署应同时报告区间宽度、条件覆盖与校准, 而非仅看点预测精度——这是本报告方法学主线的核心结论。

严谨性的价值: 本报告的阴性对照与泄漏检查“拆穿”了若干表面良好的数字 (ChemFM-GSHt、BBBP 基线), 避免把噪声当信号、把泄漏当泛化。

局限: (1) 主基准 (点预测) 数字基于验证集, 测试集仅在 conformal 一次性最终评估中使用; (2) 对接样本 $n=30$ 统计力有限, $r=-0.34$ 未达显著; (3) 点预测基准中的 Uni-Mol 经 unimol-tools 训练、库内随

机种子固定，实为单次测量——但 §6.4 的 Uni-Mol CQR 由自建训练循环驱动，已实现真正的 3 seed 变异（覆盖率标准差 0.001–0.018）；(4) 活性悬崖分析基于外部 MoleculeACE 数据，仅作确认性结论；(5) MolFormer-XL / ChemFM-3B / Uni-Mol 为外部大规模语料预训练模型，其表征隐含课程数据集以外的化学知识——此属课程“策略一：编码器”的既定用法，并未向任务数据引入额外化合物。

8 结论

本报告构建了一个完整、严谨、可复现的 ADMET 预测与结构对接 pipeline，覆盖课程的两种建模策略与全部数据集。核心结论：没有单一最优骨架——图网络（策略二）与三维模型长于回归，序列 Transformer 稳于分类，传统 RF 是极强基线，大模型 LoRA 在小数据上需谨慎；结构对接位姿几何可信（redock 0.92 Å）但打分不预测活性；现有 benchmark 划分普遍存在数据泄漏。在方法学上，我们给出跨基础模型的统一 conformal 可信度评估：量化“最紧 ≠ 有效”、揭示条件覆盖的 OOD 失效、并以 CQR 检验自适应区间能否补回欠覆盖（结论为骨架依赖）。贯穿全文的方法论基石，是对自身结果的彻底审计与诚实披露。

数据与代码可用性

数据：本研究使用课程提供的 6 个 MoleculeNet 数据集（ESOL / FreeSolv / Lipophilicity / BACE / BBBP / GSHT）； β -secretase 晶体结构 PDB 4D8C 取自公开数据库 RCSB。代码与结果：五类表征建模、conformal / CQR、结构对接与可复现性审计的脚本及结果表存于项目仓库，并经统一入口一键复跑；对接位姿验证（redock）与渲染脚本见 scripts/audit_*。面向期刊正式投稿时，应按 ACS 数据政策将代码与可公开数据存入带 DOI 的公共仓库（如 Zenodo / Hugging Face）。

参考文献

- [1] Wu Z, et al. MoleculeNet: A Benchmark for Molecular Machine Learning. Chem Sci, 2018.
- [2] Ross J, et al. Large-scale chemical language representations (MolFormer). Nat Mach Intell, 2022.
- [3] Zhou G, et al. Uni-Mol: A Universal 3D Molecular Representation Learning Framework. ICLR, 2023.
- [4] Heid E, et al. Chemprop: Machine Learning Package for Molecular Property Prediction (v2). JCIM, 2025.
- [5] Cai F, et al. ChemFM: A Foundation Model for Chemistry. 2024.
- [6] Daina A, et al. SwissADME. Sci Rep, 2017.
- [7] Trott O, Olson AJ. AutoDock Vina. J Comput Chem, 2010.
- [8] Vovk V, et al. Algorithmic Learning in a Random World (conformal prediction). Springer, 2005.
- [9] Li Y, et al. MUBen: Benchmarking the Uncertainty of Molecular Representation Models. TMLR, 2024.
- [10] Norinder U, et al. Conformal Prediction to Define Applicability Domain. JCIM, 2014.
- [11] Romano Y, Patterson E, Candès EJ. Conformalized Quantile Regression. NeurIPS, 2019.
- [12] Guo C, et al. On Calibration of Modern Neural Networks. ICML, 2017.

[13] Joeres R, et al. DataSAIL: data splitting against information leakage. Nat Commun, 2025.