

復旦大學



AI 赋能药物发现前沿 课程实验报告

课程名称：	AI 赋能药物发现前沿		
姓 名：	汤雨凡	学 号：	23307130372
学 院：	药学院	专 业：	药学

2026 年 6 月

基于机器学习与结构信息的 BACE-1 抑制剂活性预测

—— 小样本 QSAR 下表格基础模型、传统模型与分子基础模型的系统评估

实验目的

β -secretase 1 (BACE-1) 是阿尔茨海默病的关键药物靶点。本实验以 BACE 数据集 (1513 个分子) 的抑制活性 pIC50 预测为核心任务，围绕一个科学问题展开：

在小样本 BACE 这类 QSAR 任务中，新兴的“表格基础模型”能否在【点预测精度】【对新化学的外推泛化】【不确定性可信度】三条轴上，达到或超过传统 QSAR 与分子基础模型？

围绕该问题，本实验设定以下目标：(1) 在同一数据与同一划分上，公平比较覆盖课程两种建模策略的 8 个配体模型，并做统计显著性检验；(2) 不止比“谁更准”，而是解剖误差落在哪类分子上、换成新骨架是否仍成立、何时可以相信预测；(3) 以 β -secretase 晶体结构 (PDB 4D8C) 的分子对接与课题组的结构-成对模型 PBCNet2，检验结构信息能否补上配体模型的短板；(4) 全程以阴性对照、泄漏审计与显著性检验自检，诚实报告包括阴性结果在内的全部发现。

任务口径说明：BACE 在 MoleculeNet 中既可作回归 (pIC50) 也可作分类 (官方 Class 标签)。本实验聚焦 pIC50 回归 + 结构对接模块；官方 Class 为分类口径，不在本报告主线。

实验原理

1. 任务与分子表征

活性预测属回归任务，课程指标为平均绝对误差 MAE 与皮尔逊相关系数 Pearson R (辅以 RMSE、Spearman ρ)。机器学习不能直接读分子，须先把 SMILES 翻译成数值表征，课程给出两种策略：策略一“SMILES→编码器→机器学习”，策略二“SMILES→二维分子图→图神经网络”。

2. 八个模型覆盖的方法谱

- 策略一：Morgan 指纹 (r2, 2048 位) + 随机森林 / 梯度提升 / 支持向量回归 / 岭回归；分子基础模型 MolFormer-XL (11 亿分子预训练 Transformer, 47M 参数, 全参微调)、ChemFM-3B (30 亿参解码器大模型, LoRA 微调)；表格基础模型 TabPFN (前向一次、零调参, 输入 RDKit 描述符)。
- 策略二：Chemprop D-MPNN——原子为节点、化学键为边的有向消息传递图神经网络。

3. 可信度、对接与结构-成对模型

Conformal 预测在验证集上校准，给出名义覆盖 (如 90%) 的预测区间，并可按适用域 (applicability domain, 测试分子到最近训练分子的 Tanimoto 相似度) 分层检验条件覆盖。分子对接 (AutoDock Vina) 把配体放进 β -secretase 口袋打分；PBCNet2 (Yu & Sheng, 郑明月课题组) 是基于笛卡尔张量的结构-成对模型，预测一对配体在同一口袋中的相对结合活性 $\Delta pAct$ ，专为先导优化 / 活性悬崖式场景设计。

实验材料与工具

数据：课程提供的 BACE 数据集（1513 个 β -secretase 抑制剂，含 pIC50 与预定义训练/验证/测试划分）
公开蛋白结构 PDB 4D8C（ β -secretase 与共晶配体 BXD）用于对接，未引入任何外部化合物库。

软件：RDKit 2024.03（SMILES 标准化、Morgan 指纹、描述符、Murcko 骨架、活性悬崖）；scikit-learn（经典模型）、Optuna（贝叶斯调参）、TabPFN 2.0（表格基础模型）、Chemprop v2、HuggingFace Transformers + PEFT（MolFormer/ChemFM）、AutoDock Vina + Meeko（对接）、PBCNet2.0（结构-成对，作者公开 MIT 仓库）；统计用 scipy。

硬件：8 × NVIDIA RTX 5880 Ada（48 GB）服务器，conda 环境统一管理；随机性由 set_all_seeds 锁定

实验步骤

1. 数据清洗与探索性分析

在入口处一次性清洗：RDKit 解析（0 失败）、去最大片段、电荷中和（838 个）、互变异构规范化（253 个）、去隐藏重复（9 个），得到 1504 个 canonical 分子；解析失败者记录数量而非静默丢弃（图 1）。质量审计发现：约 75% 分子立体化学未定义、预定义划分测试-训练 Murcko 骨架重叠 66%、约 31% 测试分子到最近训练分子 Tanimoto>0.85；同一 canonical 分子的重复标注仅 3 对、中位差 0.16 log，说明数据在分子级别相当干净（图 2）。数据中有 242 对活性悬崖（Tanimoto>0.7 且 Δ pIC50>2，图 3），是后续误差分析与结构模块的动机。




图 1 BACE 预处理漏斗：1513 → 1504（电荷中和 838、互变异构规范 253、去隐藏重复 9）




图2 数据质量仪表盘（1504 分子）：质量计数、立体化学、测试-训练 Tanimoto、骨架重叠、类药通过率、描述符-活性相关

BACE activity cliffs: near-identical structures, large activity jumps
(red = the atoms that differ; a one-atom or stereo change moves pIC_{50} by 2-3 log units)




图3 活性悬崖结构对照 (RDKit)：近乎相同的结构、活性相差 2-3 个对数单位；红色为差异原子，第一行为纯立体翻转

2. 训练、调参与防过拟合

以全参微调的 MolFormer-XL 为例：SMILES 经分词器编码为定长 128 token，送入主干得到逐 token 隐状态，经 attention_mask 加权 masked-mean 池化压成 768 维分子向量，再过两层 MLP 回归头输出 pIC_{50} ；训练主循环为标准五步（清梯度→前向→MSE→反传→裁剪更新，配 AdamW + OneCycleLR），每个 epoch 末在验证集挑最优权重（best-on-val）：

```
enc = tok(smiles, padding="max_length", max_length=128, return_tensors="pt")
out = backbone(enc.input_ids, enc.attention_mask)
pooled = masked_mean(out.last_hidden_state, enc.attention_mask) # (B, 768)
pred = head(pooled) # predicted pIC50
# loop: zero_grad -> forward -> MSE -> backward -> clip_grad -> step (AdamW+OneCycleLR)
# best-on-val early stopping; ChemFM uses LoRA (rank 16, ~0.2% params)
```

经典模型用 Optuna TPE 贝叶斯调参，目标为 5 折交叉验证折外 MAE；所有标准化塞进 sklearn Pipeline 在折内各自拟合 (leak-safe)，避免乐观偏差 (Cawley & Talbot 2010)。防过拟合分多层：深度模型 best-on-val 早停、ChemFM LoRA 仅训 0.2% 参数、dropout 与梯度裁剪、经典模型 5 折 CV——验证与

测试 MAE 未见明显落差，未观察到明显过拟合迹象。深度模型各跑 3 个种子（42/1337/2024）报均值 $\pm$ 标准差，测试集仅最终评估一次。

3. 评估、结构模块与审计

在统一测试集（n=303）上报点预测四指标 + Friedman/配对 bootstrap 显著性 + 逐分子误差解剖 + conformal 可信度；按 Murcko 骨架严格重划做泛化压力测试；将测试集配体对接进 4D8C 并比较 docking/ML/实验活性；在活性悬崖对上检验 PBCNet2；以阴性对照（置换标签）与泄漏审计自检。

实验结果

1. 活性预测基准与统计显著性

表 1 8 个配体模型在 BACE 测试集上的活性预测（pIC50；深度模型 3 seed 均值 $\pm$ 标准差，n=303）

模型	类别	MAE $\downarrow$	Pearson R $\uparrow$
TabPFN	表格基础模型 · 零调参	0.498	0.873
Chemprop D-MPNN	策略二 · 图网络	0.551 $\pm$ 0.008	0.842 $\pm$ 0.007
RF + Morgan	策略一 · 树集成	0.554	0.841
ChemFM-3B	策略一 · 大模型 LoRA	0.559 $\pm$ 0.022	0.831 $\pm$ 0.009
GBM	策略一 · 树集成	0.569	0.835
Ridge	策略一 · 线性	0.596	0.814
SVR (RBF)	策略一 · 核方法	0.599	0.815
MolFormer-XL	策略一 · 全参微调	0.674 $\pm$ 0.054	0.775 $\pm$ 0.035

TabPFN 在 MAE 与 Pearson R 上均为最佳点估计。统计上：Friedman 检验 $p=1.3 \times 10^{-5}$ ；临界差异图（Nemenyi，较保守，图 5）将 TabPFN、Chemprop、RF、ChemFM 归为同一第一梯队，显著优于 Ridge、SVR 与 MolFormer；更敏感的逐分子配对 bootstrap 进一步可将 RF、GBM 与 TabPFN 分开（两种检验灵敏度不同）。因此严谨表述为：TabPFN 与图网络、化学大模型同属第一梯队，而非全面碾压 MolFormer 全参微调在小数据上方差最大、表现最弱。




图 4 全模型测试 MAE (深度模型 3 seed 误差棒; TabPFN 最低)




图 5 临界差异图 (Friedman $p=1.3e-5$, $n=303$) : 横轴为逐分子误差平均秩, 红条相连者差异不显著

2. 调参的真实增量与“是否还需要调参”

调参的诚实结论 (图 6) : 对欠正则模型 (岭回归默认在 2048 维上几乎失效, R 0.65 $\rightarrow$ 0.81) 调参大幅受益, 对随机森林/梯度提升等“默认即好”的树集成仅边际改善、个别略降——“调参总涨分”是误区。更进一步, 在本实验预算内, 任何 Optuna 预算 (梯度提升 80 trial、约 986 秒) 都未追上零调参的 TabPFN (约 5 秒、MAE 0.498, 图 7) ; 数据效率曲线显示 TabPFN 在各训练量均领先、样本最少时差距最大, 与小样本 BACE 高度契合。

F12 Default vs tuned (test set): tuning helps, but honestly by how much




图 6 默认 vs Optuna 调参 (测试集) : 欠正则模型大幅受益, 树集成仅边际




图 7 TabPFN（零调参）vs Optuna 调参的经典模型：精度 vs 调参耗时（红星 = TabPFN）

3. 逐分子误差解剖

误差并非随机：所有模型都“回归到均值”（低估高活性、高估低活性，TabPFN 收缩最小）；误差最大的十分位分子中，19% 落在活性悬崖（其余仅 1%）、16% 为标签冲突骨架（其余 2%），且更偏新骨架与极端活性（图 8）；跨 8 模型共识最难分子多为大环、碎片样小分子或极端活性（图 9）。调参只缩小误差幅度、不改变“谁难”（大误差集合重叠 76%）。TabPFN 的预测区间宽度可提前标出难分子——58% 的共识难例落在其 90% 区间之外（易预测分子仅 6%，图 10）。

A3 What distinguishes the top-decile-error molecules (hard) from the rest (easy)




图 8 大误差（共识 top-decile）分子 vs 其余：前者更新（低 Tanimoto）、活性更极端、更常落在悬崖与标签冲突上




图 9 跨 8 模型共识最难的 12 个分子 (结构 + 真实 pIC50 + 平均误差)

A7 TabPFN uncertainty flags hard molecules + conformal calibration (nominal 90%)




图 10 TabPFN 不确定性提前标出难分子：拒识最不确定者后保留集 MAE 明显下降；58% 难例落在 90% 区间外

4. 外推泛化与可信度

预定义划分有 66% 骨架重叠、会高估泛化。按 Murcko 骨架严格重划 (训练/测试无共享骨架) 重训全部 8 模型后 (图 11)：TabPFN 几乎不退化 (MAE 0.498→0.508，仍最低、差距最小)，全参微调的 MolFormer 泛化性能明显退化 (0.674→1.134) —— TabPFN 对新化学的外推在本实验中表现最稳。可信度方面 (图 12，名义 90%，仅用验证集校准、全模型同一协议、测试集不参与调 coverage)：各模

型边缘覆盖率均达标 (0.90–0.95)，Chemprop 区间最紧；但按相似度分层，多数模型在低相似度（新骨架）子群覆盖率降至 0.2–0.5（低 AD 子群 n=10，为探索性结果，需更大外部集验证），TabPFN 在低 AD 仍接近 0.9。

B Generalization stress test: predefined split vs Murcko scaffold split (novel chemistry)




图 11 泛化压力测试：预定义 vs Murcko 骨架严格划分的测试 MAE 与 Pearson；TabPFN 两 split 都最低、差距最小

A Conformal-prediction benchmark across models + AD-conditional coverage (BACE, 90%)




图 12 Conformal 全模型基准（名义 90%）：(a) 覆盖率 vs 区间宽度；(b) 按适用域分层的条件覆盖——低 AD 普遍欠覆盖

5. 结构对接与 PBCNet2

将测试集配体用 Vina 对接进 4D8C（图 13）：对接打分与实验活性的相关较弱（Pearson -0.33），且控制分子尺寸后接近 0（偏相关 -0.17）——因为活性配体偏大、Vina 又偏好大配体，是尺寸混淆；监督 QSAR 在同一测试集上相关性更高（R 0.84–0.87），但两者用途不同（对接给的是结合位姿，不作同类性能比较）。共晶配体 BXD 重对接 RMSD 仅 1.13 Å，支持基础对接设置合理（图 14）。在 161 个活性悬崖对上检验 PBCNet2（指标为相对 ΔpIC_{50} 排序 |Spearman ρ |，已按 $\Delta\Delta G$ 符号对齐）：其排序 (0.375，约束位姿复测 0.174) 低于配体模型 (0.78) ——这是一个诚实的阴性结果，可能主要受 cross-docking 位姿质量限制（而非 PBCNet2 本身——它在 FEP 基准上表现优异），界定了结构-成对模型的适用范围（图 15）。




图 13 对接 vs 活性 vs ML：(a) Vina 打分 vs 实验 pIC_{50} （按重原子数着色，尺寸混淆）；(b) |Pearson| 对比——监督 QSAR 相关性更高




图 14 PBCNet2（两种位姿协议）vs 配体模型在活性悬崖上的相对活性排序 |Spearman|

讨论与思考

本实验围绕一个科学问题给出三条相互印证的证据，统一指向“对新化学的泛化”这一主线：

- 零调参的表格基础模型 TabPFN 在点预测、scaffold 外推、conformal 条件覆盖三条轴上对新化学的泛化都最好；它与 Chemprop、ChemFM 同属第一梯队，并显著优于调参后的线性/核模型与全参微调的 MolFormer。
- 误差不是随机的：高度集中在活性悬崖、标签冲突、新骨架与极端活性分子；调参只缩小幅度、不改变“谁难”；不确定性可提前标出这些难分子，使“何时别信模型”变得可操作。
- 结构方法（对接 / PBCNet2）在本设置下未能补位：Vina 打分弱且受尺寸混淆，PBCNet2 在对接位姿上未超过配体模型——这是一个界定适用范围的阴性结果，瓶颈可能主要在位姿质量而非模型类别。

方法论思考：本实验最看重的不是把某个数字刷高，而是让每个结论都能被质疑也能被辩护——用阴性对照排除随机标签记忆、用 scaffold split 量化并披露相似性泄漏、用统计检验约束“显著”一词、对结构方法的阴性结果不作过度归因。这是把“看起来很准”升级为“知道它何时可信”的关键。

局限：(1) 单数据集（BACE），结论外推到其他靶点需验证；(2) 预定义划分存在骨架泄漏，已用 scaffold split 缓解并披露；(3) PBCNet2 的检验受限于 cross-docking 位姿质量、缺少共晶位姿；(4) 低相似度子样本量小（n=10），相关结论为探索性；(5) 未做前瞻性实验验证。

结论

在小样本 BACE-1 抑制活性预测上，零调参的表格基础模型 TabPFN 给出最优点估计，并在统计显著性、骨架外推鲁棒性、conformal 条件覆盖三条轴上对新化学的泛化均达第一梯队或最稳；模型误差系统性集中在活性悬崖、标签冲突与新骨架，且可被不确定性提前标出；结构方法（对接、PBCNet2）在 cross-docking 位姿域未能超过配体模型，构成一个界定适用范围的阴性结果。全程以阴性对照、泄漏审计与显著性检验自检，结论既可被质疑也可被辩护。

参考文献

- [1] VASSAR R, BENNETT B D, BABU-KHAN S, et al. β -secretase cleavage of Alzheimer's amyloid precursor protein by the transmembrane aspartic protease BACE[J]. *Science*, 1999, 286(5440): 735-741. DOI: 10.1126/science.286.5440.735.
- [2] WU Z, RAMSUNDAR B, FEINBERG E N, et al. MoleculeNet: a benchmark for molecular machine learning[J]. *Chemical Science*, 2018, 9(2): 513-530. DOI: 10.1039/C7SC02664A.
- [3] SUBRAMANIAN G, RAMSUNDAR B, PANDE V, et al. Computational modeling of β -secretase 1 (BACE-1) inhibitors using ligand based approaches[J]. *Journal of Chemical Information and Modeling*, 2016, 56(10): 1936-1949. DOI: 10.1021/acs.jcim.6b00290.
- [4] ROGERS D, HAHN M. Extended-connectivity fingerprints[J]. *Journal of Chemical Information and Modeling*, 2010, 50(5): 742-754. DOI: 10.1021/ci100050t.
- [5] HOLLMANN N, MÜLLER S, PURUCKER L, et al. Accurate predictions on small data with a tabular foundation model[J]. *Nature*, 2025, 637(8045): 319-326. DOI: 10.1038/s41586-024-08328-6.
- [6] ROSS J, BELGODERE B, CHENTHAMARAKSHAN V, et al. Large-scale chemical language representations capture molecular structure and properties[J]. *Nature Machine Intelligence*, 2022, 4(12): 1256-1264. DOI: 10.1038/s42256-022-00580-7.
- [7] HEID E, GREENMAN K P, CHUNG Y, et al. Chemprop: a machine learning package for chemical property prediction[J]. *Journal of Chemical Information and Modeling*, 2024, 64(1): 9-17. DOI: 10.1021/acs.jcim.3c01250.
- [8] CAWLEY G C, TALBOT N L C. On over-fitting in model selection and subsequent selection bias in performance evaluation[J]. *Journal of Machine Learning Research*, 2010, 11: 2079-2107.
- [9] AKIBA T, SANO S, YANASE T, et al. Optuna: a next-generation hyperparameter optimization framework[C]//*Proceedings of the 25th ACM SIGKDD*. 2019: 2623-2631. DOI: 10.1145/3292500.3330701.
- [10] DEMŠAR J. Statistical comparisons of classifiers over multiple data sets[J]. *Journal of Machine Learning Research*, 2006, 7: 1-30.
- [11] MAGGIORA G M. On outliers and activity cliffs — why QSAR often disappoints[J]. *Journal of Chemical Information and Modeling*, 2006, 46(4): 1535. DOI: 10.1021/ci060117s.
- [12] EBERHARDT J, SANTOS-MARTINS D, TILLACK A F, et al. AutoDock Vina 1.2.0[J]. *Journal of Chemical Information and Modeling*, 2021, 61(8): 3891-3898. DOI: 10.1021/acs.jcim.1c00203.
- [13] YU J, SHENG X, et al. Advancing ligand binding affinity prediction with Cartesian-tensor-based deep learning (PBCNet2.0) [J]. *Nature Chemical Biology*, 2026. DOI: 10.1038/s41589-026-02241-x.
- [14] ANGELOPOULOS A N, BATES S. Conformal prediction: a gentle introduction[J]. *Foundations and Trends in Machine Learning*, 2023, 16(4): 494-591. DOI: 10.1561/2200000101.
- [15] ROMANO Y, PATTERSON E, CANDÈS E J. Conformalized quantile regression[C]//*NeurIPS* 32. 2019.

附录

A. 可复现性审计：阴性对照——置换训练标签后用同一流程重训，RF / GBM / TabPFN 测试 Pearson R 分别降至 -0.11 / -0.04 / -0.05，支持 $R \approx 0.84-0.87$ 来自可学习的结构-活性信号、而非对随机标签的记忆
泄漏审计——预定义划分骨架重叠 66%、31% 测试分子 Tanimoto > 0.85，scaffold split 已将相似性虚高剥离（RF MAE 0.554 → 0.684）。统一 set_all_seeds、3 seed、调参只用验证 / 折内 CV、测试集只看一次
所有图由 scripts/ 脚本一键重出。

B. 完整指标（深度模型 3 seed 均值±标准差，n=303）：

模型	MAE	RMSE	Pearson R	Spearman ρ
TabPFN	0.498	0.668	0.873	0.834
Chemprop	0.551±0.008	0.737±0.015	0.842±0.007	0.827±0.009
RF	0.554	0.747	0.841	0.822
ChemFM-3B	0.559±0.022	0.762±0.021	0.831±0.009	0.816±0.007
GBM	0.569	0.753	0.835	0.813
Ridge	0.596	0.796	0.814	0.802
SVR	0.599	0.793	0.815	0.797
MolFormer-XL	0.674±0.054	0.885±0.057	0.775±0.035	0.733±0.034

C. 数据与代码可用性：本研究使用课程提供的 BACE 数据集与公开蛋白结构 PDB 4D8C；建模、调参、误差解剖、对接、PBCNet2、conformal 与审计脚本及结果表存于项目仓库，经统一入口一键复跑；PBCNet2 代码与权重来自作者公开 MIT 仓库。