

復旦大學



AI 赋能药物发现前沿 课程实验报告

课程名称:	AI 赋能药物发现前沿		
姓 名:	汤雨凡	学 号:	23307130372
学 院:	计算与智能创新学院	专 业:	计算机科学与技术

2026 年 6 月

基于机器学习与结构信息的 BACE-1 抑制剂活性预测

小样本 QSAR 下表格基础模型、传统模型与分子基础模型的系统评估

实验目的

β -secretase 1 (BACE-1) 是阿尔茨海默病的关键药物靶点。本实验以 BACE 数据集 (1513 个分子) 的抑制活性 pIC_{50} 预测为核心任务，围绕一个科学问题展开：

在小样本 BACE 这类 QSAR 任务中，新兴的“表格基础模型”能否在【点预测精度】【对新化学的外推泛化】【不确定性可信度】三条轴上，达到或超过传统 QSAR 与分子基础模型？

围绕该问题，本实验设定以下目标：(1) 在同一数据与同一划分上，公平比较覆盖课程两种建模策略的 8 个配体模型，并做统计显著性检验；(2) 不止比“谁更准”，而是解剖误差落在哪类分子上、换成新骨架是否仍成立、何时可以相信预测；(3) 以 β -secretase 晶体结构 (PDB 4D8C) 的分子对接与课题组的结构-成对模型 PBCNet2，检验结构信息能否补上配体模型的短板；(4) 全程以阴性对照、泄漏审计与显著性检验自检，诚实报告包括阴性结果在内的全部发现。

任务口径说明：BACE 在 MoleculeNet 中既可作回归 (pIC_{50}) 也可作分类 (官方 Class 标签)。本实验聚焦 pIC_{50} 回归 + 结构对接模块，不以官方 Class 为训练目标；但在结果中由 pIC_{50} 阈值化派生一条分类评估轴 (见结果 §8)，作为对回归模型实用能力的附加考察。

课程内容对应：本项目遵循课程项目要求，完成“数据整理→模型构建→训练→分析”的完整链路；实现上用 RDKit + scikit-learn / Chemprop / HuggingFace Transformers 在同一数据任务上复现。各课程环节与本项目的对应关系如下表。

课程环节	本项目对应内容
数据整理	清洗漏斗 / 去重 / Murcko 骨架与泄漏审计 (图 1-2)
分子表征	Morgan 指纹 + RDKit 物化描述符 + 多指纹消融 (结果 §6)
模型构建	策略一：传统 ML (RF/GBM/SVR/Ridge) + 基础模型 (MolFormer/ChemFM/TabPFN) ； 策略二：Chemprop D-MPNN 图网络
训练与评估	Optuna 调参 + 5 折 CV + 3 seed；MAE / Pearson R (回归)、ROC-AUC / MCC (分类)、早期富集 EF

课程环节	本项目对应内容
药物发现应用	β -secretase 4D8C 分子对接 (Vina) / PBCNet2 结构-成对模型 / 活性悬崖分析
可复现性	scaffold split + 泄漏审计 + 阴性对照 + 显著性检验 + conformal/AD 分层

实验原理

1. 任务与分子表征

活性预测属回归任务，课程指标为平均绝对误差 MAE 与皮尔逊相关系数 Pearson R（辅以 RMSE、Spearman ρ ）。机器学习不能直接读分子，须先把 SMILES 翻译成数值表征，课程给出两种策略：策略一“SMILES→编码器→机器学习”，策略二“SMILES→二维分子图→图神经网络”。

2. 八个模型覆盖的方法谱

- **策略一：**Morgan 指纹 (r2, 2048 位) + 随机森林 / 梯度提升 / 支持向量回归 / 岭回归；分子基础模型 MolFormer-XL (11 亿分子预训练 Transformer, 47M 参数, 全参微调)、ChemFM-3B (30 亿参解码器大模型, LoRA 微调)；表格基础模型 TabPFN (前向一次、零调参, 输入 RDKit 描述符)。
- **策略二：**Chemprop D-MPNN: 原子为节点、化学键为边的有向消息传递图神经网络。

3. 可信度、对接与结构-成对模型

Conformal 预测在验证集上校准，给出名义覆盖（如 90%）的预测区间，并可按适用域 (applicability domain, 测试分子到最近训练分子的 Tanimoto 相似度) 分层检验条件覆盖。分子对接 (AutoDock Vina) 把配体放进 β -secretase 口袋打分；PBCNet2 (Yu & Sheng, 郑明月课题组) 是基于笛卡尔张量的结构-成对模型，预测一对配体在同一口袋中的相对结合活性 $\Delta pAct$ ，专为先导优化 / 活性悬崖式场景设计。

实验材料与工具

数据：课程提供的 BACE 数据集 (1513 个 β -secretase 抑制剂, 含 pIC50 与预定义训练/验证/测试划分) 公开蛋白结构 PDB 4D8C (β -secretase 与共晶配体 BXD) 用于对接, 未引入任何外部化合物库。

软件：RDKit 2024.03（SMILES 标准化、Morgan 指纹、描述符、Murcko 骨架、活性悬崖）；scikit-learn（经典模型）、Optuna（贝叶斯调参）、TabPFN 2.0（表格基础模型）、Chemprop v2、HuggingFace Transformers + PEFT（MolFormer/ChemFM）、AutoDock Vina + Meeko（对接）、PBCNet2.0（结构-成对，作者公开 MIT 仓库）；统计用 scipy。

硬件：8 × NVIDIA A100（80 GB）服务器，conda 环境统一管理；随机性由 set_all_seeds 锁定。

实验步骤

1. 数据清洗与探索性分析

在入口处一次性清洗：RDKit 解析（0 失败）、去最大片段、电荷中和（838 个）、互变异构规范化（253 个）、去隐藏重复（9 个），得到 1504 个 canonical 分子；解析失败者记录数量而非静默丢弃（图 1）。质量审计发现：约 75% 分子立体化学未定义、预定义划分测试-训练 Murcko 骨架重叠约 64%（63.7%）、约 29%（29.4%）测试分子到最近训练分子 Tanimoto>0.85；同一 canonical 分子的重复标注仅 3 对、中位差 0.16 log，说明数据在分子级别相当干净（图 2）。数据中有 242 对活性悬崖（Tanimoto>0.7 且 $\Delta pIC_{50}>2$ ，图 3），是后续误差分析与结构模块的动机。




图 1 BACE 预处理漏斗：1513 → 1504（电荷中和 838、互变异构规范 253、去隐藏重复 9）




图2 数据质量仪表盘 (1504 分子)：质量计数、立体化学、测试-训练 Tanimoto、骨架重叠、类药通过率、描述符-活性相关

BACE activity cliffs: near-identical structures, large activity jumps
(red = the atoms that differ; a one-atom or stereo change moves pIC_{50} by 2-3 log units)




图3 活性悬崖结构对照 (RDKit)：近乎相同的结构、活性相差 2-3 个对数单位；红色为差异原子，第一行为纯立体翻转

2. 训练、调参与防过拟合

以全参微调的 MolFormer-XL 为例：SMILES 经分词器编码为定长 128 token，送入主干得到逐 token 隐状态，经 attention_mask 加权 masked-mean 池化压成 768 维分子向量，再过两层 MLP 回归头输出 pIC_{50} ；训练主循环为标准五步（清梯度→前向→MSE→反传→裁剪更新，配 AdamW + OneCycleLR），每个 epoch 末在验证集挑最优权重（best-on-val）：

```
enc = tok(smiles, padding="max_length", max_length=128, return_tensors="pt")
out = backbone(enc.input_ids, enc.attention_mask)
pooled = masked_mean(out.last_hidden_state, enc.attention_mask) # (B, 768)
pred = head(pooled) # predicted pIC50
# loop: zero_grad -> forward -> MSE -> backward -> clip_grad -> step (AdamW+OneCycleLR)
# best-on-val early stopping; ChemFM uses LoRA (rank 16, ~0.2% params)
```

经典模型用 Optuna TPE 贝叶斯调参，目标为 5 折交叉验证折外 MAE；所有标准化塞进 sklearn Pipeline 在折内各自拟合（leak-safe），避免乐观偏差（Cawley & Talbot 2010）。防过拟合分多层：深度模型 best-on-val 早停、ChemFM LoRA 仅训 0.2% 参数、dropout 与梯度裁剪、经典模型 5 折 CV；验证与测试 MAE 未见明显落差，未观察到明显过拟合迹象。深度模型各跑 3 个种子（42/1337/2024）报均值±标准差，测试集仅最终评估一次。

3. 评估、结构模块与审计

在统一测试集（n=303）上报点预测四指标 + Friedman/配对 bootstrap 显著性 + 逐分子误差解剖 + conformal 可信度；按 Murcko 骨架严格重划做泛化压力测试；将测试集配体对接进 4D8C 并比较 docking/ML/实验活性；在活性悬崖对上检验 PBCNet2；以阴性对照（置换标签）与泄漏审计自检。此外补充三项课程方法学深化：表征消融（固定随机森林、更换第五讲指纹清单）、特征与子结构可解释性（置换重要性 + Morgan 位渲染）、以及由 pIC50 派生的分类（ROC-AUC/PR-AUC/F1/MCC）与早期富集（EF）评估轴。

实验结果

1. 活性预测基准与统计显著性

表 1 8 个配体模型在 BACE 测试集上的活性预测（pIC50；深度模型 3 seed 均值±标准差，n=303）

模型	类别	MAE ↓	Pearson R ↑
TabPFN	表格基础模型 + 零调参	0.498	0.873
Chemprop D-MPNN	策略二 + 图网络	0.551 ± 0.008	0.842 ± 0.007
RF + Morgan	策略一 + 树集成	0.554	0.841
ChemFM-3B	策略一 + 大模型 LoRA	0.559 ± 0.022	0.831 ± 0.009
GBM	策略一 + 树集成	0.569	0.835
Ridge	策略一 + 线性	0.596	0.814
SVR (RBF)	策略一 + 核方法	0.599	0.815
MolFormer-XL	策略一 + 全参微调	0.673 ± 0.054	0.775 ± 0.035

TabPFN 在 MAE 与 Pearson R 上均为最佳点估计（表 1、图 4）。关于显著性需谨慎区分两类检验：基于 n=303 个测试分子的 Friedman + Nemenyi 临界差异图（图 5）把逐分子误差当作配对块，分子并非独

立重复（伪重复），因此本报告只把它当作**描述性可视化**，不作为严格显著性判据。严格的显著性来自两条互补证据：(i) 逐分子配对 bootstrap（10k 重采样 + Bonferroni）给出 Δ MAE 的置信区间，进一步将 RF、GBM 与 TabPFN 分开；(ii) 论文级的折级 Nadeau–Bengio 校正重采样检验（以折而非分子为重复单元，避免伪重复）。两类检验灵敏度不同。综合的严谨表述为：TabPFN 与图网络、化学大模型同属第一梯队；MolFormer 全参微调在小数据上方差最大、表现最弱。



图4 全模型测试 MAE（深度模型 3 seed 误差棒；TabPFN 最低）




图5 临界差异图（Friedman $p=1.3e-5$, $n=303$ ，仅作描述性可视化，逐分子非独立重复）：横轴为逐分子误差平均秩；严格显著性见配对 bootstrap 与折级 Nadeau–Bengio 检验

2. 调参的真实增量与“是否还需要调参”

调参的诚实结论（图6）：对欠正则模型（岭回归默认在 2048 维上几乎失效， $R\ 0.65 \rightarrow 0.81$ ）调参大幅受益，对随机森林/梯度提升等“默认即好”的树集成仅边际改善、个别略降，可见调参不必然带来稳定增益。进一步，在本实验预算内，任何 Optuna 预算（梯度提升 80 trial、约 986 秒）都未追上零调参

的 TabPFN（约 5 秒、MAE 0.498，图 7）；在该预算的耗时-误差权衡上，零调参的 TabPFN 最优，与小样本 BACE 场景契合。

F12 Default vs tuned (test set): tuning helps, but honestly by how much




图 6 默认 vs Optuna 调参（测试集）：欠正则模型大幅受益，树集成仅边际

E1 TabPFN (zero-tuning) vs Optuna-tuned classic ML on BACE




图 7 TabPFN（零调参）vs Optuna 调参的经典模型：精度 vs 调参耗时（红星 = TabPFN）

3. 逐分子误差解剖

误差并非随机：所有模型都“回归到均值”（低估高活性、高估低活性，TabPFN 收缩最小）；误差最大的十分位分子中，19% 落在活性悬崖（其余仅 1%）、16% 为标签冲突骨架（其余 2%），且更偏新骨架与极端活性（图 8）；跨 8 模型共识最难的分子多为大环、碎片样小分子或极端活性（图 9）。调参只缩小误差幅度、不改变“谁难”（大误差集合重叠 76%）。TabPFN 的预测区间宽度可预警高风险、支持拒识策略（难例按测试误差事后定义，但区间宽度在预测时即可用）：58% 的共识难例落在其 90% 区间之外（易预测分子仅 6%，图 10）。




图 8 大误差（共识 top-decile）分子 vs 其余：前者更新（低 Tanimoto）、活性更极端、更常落在悬崖与标签冲突上




图 9 跨 8 模型共识最难的 12 个分子（结构 + 真实 pIC50 + 平均误差）

A7 TabPFN uncertainty flags hard molecules + conformal calibration (nominal 90%)




图 10 TabPFN 不确定性预警高误差风险：拒识最不确定者后保留集 MAE 明显下降；58% 难例落在 90% 区间外

4. 外推泛化与可信度

预定义划分有约 64% 骨架重叠、会高估泛化。按 Murcko 骨架严格重划（训练/测试无共享骨架）重训全部 8 模型后（图 11）：TabPFN 几乎不退化（MAE 0.498→0.508，仍最低、差距最小），全参微调的 MolFormer 泛化性能明显退化（0.673→1.134）；TabPFN 对新化学的外推在本实验中表现最稳。可信度方面（图 12，名义 90%，仅用验证集校准、全模型同一协议、测试集不参与调 coverage）：各模型边际覆盖率均达标（0.90–0.95），Chemprop 区间最紧；但按相似度分层，8 个模型中有 6 个在低相似度（新骨架）子群覆盖率降至 0.2–0.5（低 AD 子群 n=10，为探索性结果，需更大外部集验证），仅 TabPFN 与 MolFormer 在低 AD 仍接近 0.9（MolFormer 的代价是区间显著更宽，TabPFN 则同时保持紧致）。

B Generalization stress test: predefined split vs Murcko scaffold split (novel chemistry)




图 11 泛化压力测试：预定义 vs Murcko 骨架严格划分的测试 MAE 与 Pearson；TabPFN 两 split 都最低、差距最小

A Conformal-prediction benchmark across models + AD-conditional coverage (BACE, 90%)




图 12 Conformal 全模型基准（名义 90%）：(a) 覆盖率 vs 区间宽度；(b) 按适用域分层的条件覆盖：低 AD 普遍欠覆盖

5. 结构对接与 PBCNet2

将测试集配体用 Vina 对接进 4D8C（图 13）：对接打分与实验活性的相关较弱（Pearson -0.33 ），且控制分子尺寸后接近 0（偏相关 -0.17 ），因为活性配体偏大、Vina 又偏好大配体，是尺寸混淆；监督 QSAR 在同一测试集上相关性更高（R $0.84-0.87$ ），但两者用途不同（对接给的是结合位姿，不作同类性能比较）。共晶配体 BXD 重对接 RMSD 仅 $1.13 \text{ \AA}$ ，支持基础对接设置合理。在 161 个活性悬崖对上检验 PBCNet2（指标为相对 ΔpIC_{50} 排序 [Spearman ρ]，已按 $\Delta\Delta G$ 符号对齐）：其排序（0.375，约束位姿复测 0.174）低于配体模型（0.78）。这是一个诚实的阴性结果，可能主要受 cross-docking 位姿质量限制（而非 PBCNet2 本身，它在 FEP 基准上表现优异），界定了结构-成对模型的适用范围（图 14）。需要说明的是，悬崖对之间存在共享配体，pair-level 相关性不应解释为 161 个完全独立样本。




图 13 对接 vs 活性 vs ML: (a) Vina 打分 vs 实验 pIC_{50} (按重原子数着色, 尺寸混淆); (b) |Pearson| 对比: 监督 QSAR 相关性更高




图 14 PBCNet2 (两种位姿协议) vs 配体模型在活性悬崖上的相对活性排序 |Spearman|

6. 表征消融：模型排名是否依赖指纹选择

为排除“基准排名只是 Morgan 指纹的产物”这一可能，固定模型为随机森林、只更换分子表征，覆盖课程第五讲给出的指纹清单（Morgan、Atom Pair、Topological Torsion、MACCS、Avalon）与 RDKit 217 维物化描述符，在同一划分上各跑 3 个种子（表 2、图 15）。Morgan (MAE 0.559) 与 Topological Torsion 并列最优，Atom Pair 的 Pearson R 最高 (0.847)，三者同属第一梯队；低容量的 MACCS (167 位) 明显最弱 (MAE 0.609)。两点结论：其一，主基准选用 Morgan 合理，它处在表征第一梯队；其二，固定模型下不同表征的 MAE 仅相差约 0.05，远小于模型之间的差距，模型排名并非表征选择的假象。此处未调参的 RF+Morgan (0.559) 与基准表中经 Optuna 调参的 RF (0.554) 几乎一致，互为印证

表 2 固定随机森林、仅更换分子表征的活性预测 (测试集, 3 seed 均值, 按 MAE 升序)

分子表征	维度	MAE ↓	Pearson R ↑
Morgan (ECFP4)	2048 位	0.559	0.837
Topological Torsion	2048 位	0.559	0.833
Atom Pair	2048 位	0.566	0.847
Avalon	2048 位	0.574	0.824
RDKit 描述符	217 维	0.593	0.840
MACCS keys	167 位	0.609	0.807




图 15 表征消融（模型固定为随机森林）：(a) 测试 MAE；(b) 测试 Pearson R：Morgan / Atom Pair / Topological Torsion 同属第一梯队，MACCS 最弱

进一步固定 Morgan、做配置与特征选择的稳健性检查：radius 2 vs $3 \times 1024/2048/4096$ 的扫描中，r2/2048 与最优配置 r2/4096 仅相差 0.006 MAE、加大半径（radius 3）不带来增益；对 Morgan-2048 做特征选择（方差阈值保留 783 位、互信息 top-512、Lasso 选 53 位，选择器均仅在训练集拟合以防泄漏）对随机森林无改善（树集成自带隐式特征选择），而激进的 Lasso 53 位选择反而明显变差（RF MAE 0.559→0.592、Ridge 0.596→0.741）。因此选用全 2048 位 Morgan (r2) 合理，额外的指纹半径/位数调参或特征选择在本任务上无实质收益。

7. 特征与子结构可解释性

为回答“模型究竟学到了什么化学”，对随机森林做两层可解释性分析（均不依赖额外黑箱工具）。其一，在 RDKit 描述符上用置换重要性（permutation importance，测试集 R^2 的下降量）排序（图 16）：分子大小/连接度类描述符主导（Chi0 居首，与 pIC50 的 Spearman $\rho=+0.47$ ；重原子量、分子复杂度 BertzCT 同为正相关），辅以 E-state 电子拓扑指数，表明在该 BACE 同系物系列中，更大、更复杂的分子普遍更强（描述符彼此高度相关，应按“主题”而非单个特征解读）。其二，把随机森林重

要性最高的 Morgan 位映射回原子环境并渲染为子结构（图 17）：可定位若干增效 / 致弱基团（如某含氟芳环环境一旦出现，平均 pIC50 下降约 1.73）。该视角呼应课程对“可解释性 + 适用域”的强调，也为先导优化指明取舍方向。




图 16 描述符置换重要性（随机森林）：分子大小 / 复杂度（Chi0、BertzCT）与 E-state 指数主导；蓝 = 与 pIC50 正相关，红 = 负相关




图 17 随机森林重要性最高的 6 个 Morgan 子结构及其对平均 pIC50 的方向（绿 = 增效，红 = 致弱）

8. 分类与早期富集：回归之外的两条评估轴

BACE 在作业中是回归任务（主指标 MAE + Pearson R）；为完整演练课程第五讲的评估指标、并考察模型的实用能力，补充两条由回归预测派生的评估轴（同一测试集，复用预测、不重新训练）。

分类轴（表 3、图 18）：以 $pIC_{50} \geq 7$ ($IC_{50} \leq 100$ nM；测试集 43.9% 为活性、类别均衡）二分，用连续预测 pIC_{50} 作打分计算 ROC-AUC / PR-AUC，在阈值 7 处二值化算 F1 / MCC。Chemprop 图网络给出最高 ROC-AUC (0.915) 与 MCC (0.650)，TabPFN 次之 (0.900 / 0.631)。一个值得注意的细节：回归点估计最优的 TabPFN 在分类轴上略逊于 Chemprop，没有单一模型在所有评估轴上都最优，评估口径会改变“谁最好”的结论。

早期富集轴（图 19）：模拟先导优化中“能否把最强的分子排到最前”。以最高活性 10% ($pIC_{50} \geq 8.04$, $n=31$) 为高活性命中、按预测活性降序计算富集因子 EF。最稳的 EF@10%（前 30 个）以 ChemFM (6.84)、随机森林 (5.86) 领先，各模型在前 5–10% 富集约 4–7 倍于随机；MolFormer 最弱，与其回归表现一致 (EF@1% 仅含 3 个分子、噪声大，仅作参考)。

表 3 回归模型的分类视角 (active = $pIC_{50} \geq 7$ ，测试集 $n=303$ ，按 ROC-AUC 降序)

模型	ROC-AUC ↑	PR-AUC ↑	F1 ↑	MCC ↑
Chemprop	0.915	0.888	0.797	0.650
TabPFN	0.900	0.858	0.792	0.631
GBM	0.900	0.865	0.761	0.603
ChemFM-3B	0.899	0.855	0.753	0.576
RF + Morgan	0.893	0.854	0.751	0.576
Ridge	0.885	0.840	0.725	0.557
SVR (RBF)	0.879	0.840	0.741	0.562
MolFormer-XL	0.865	0.798	0.758	0.571




图 18 分类视角：(a) 8 个模型的 ROC 曲线（active = pIC₅₀ ≥ 7.0）；(b) MCC：Chemprop 最高，回归最优的 TabPFN 在分类轴略逊




图 19 早期富集（高活性 = 最高 10%，pIC₅₀ ≥ 8.04）：(a) 富集曲线；(b) EF@5%：各模型在排序表头富集约 4–7 倍于随机

讨论与思考

本实验围绕一个科学问题给出三条相互印证的证据，统一指向“对新化学的泛化”这一主线：

- 零调参的表格基础模型 TabPFN 在点预测上为最佳点估计，在 scaffold 外推与低 AD 条件覆盖上表现最稳，整体属于第一梯队；它与 Chemprop、RF、ChemFM 同属第一梯队。显著性依检验口径而定：在逐分子配对 bootstrap 与主分析 $p=1/9$ 的 Nadeau–Bengio 检验下，TabPFN 显著优于线性/核模型与 RF/GBM；但在保守 $p=0.25$ NB-Holm 校正下，仅全参微调的 MolFormer 仍显著更差，其余差异不显著。

- 误差不是随机的：高度集中在活性悬崖、标签冲突、新骨架与极端活性分子；调参只缩小幅度、不改变“谁难”；不确定性可预警高误差风险、支持拒识策略，使“何时降低预测可信度”变得可操作。
- 结构方法（对接 / PBCNet2）在本设置下未能弥补配体模型短板：Vina 打分弱且受尺寸混淆，PBCNet2 在对接位姿上未超过配体模型。这是一个界定适用范围的阴性结果，瓶颈可能主要在位姿质量而非模型类别。
- 表征与评估口径的稳健性检查进一步支撑主结论：固定模型只换指纹，模型排名不变（Morgan 处第一梯队）；换成分类（ROC-AUC / MCC）与早期富集（EF）两条轴后，各模型整体仍可用，但“谁第一”随口径轻微变化（回归看 TabPFN、分类看 Chemprop）。评估应多轴并看，不可只报单一指标。
- 可解释性显示模型抓到的是可学习的结构-活性相关信号：分子大小 / 复杂度与若干增效 / 致弱子结构主导预测，而非记忆噪声（与附录阴性对照相互印证）。

方法论思考：本实验最看重的不是优化单一数值指标，而是让每个结论都能被质疑也能被辩护：用阴性对照排除随机标签记忆、用 scaffold split 量化并披露相似性泄漏、用统计检验约束“显著”一词、对结构方法的阴性结果不作过度归因。这是把“看起来很准”升级为“知道它何时可信”的关键。

局限：(1) 单数据集（BACE），结论外推到其他靶点需验证；(2) 预定义划分存在骨架泄漏，已用 scaffold split 缓解并披露；(3) PBCNet2 的检验受限于 cross-docking 位姿质量、缺少共晶位姿；(4) 低相似度子群样本量小（n=10），相关结论为探索性；(5) 未做前瞻性实验验证。

研究范围界定：本实验聚焦先导优化阶段的“活性预测 + 结构复核”，未涉及分子生成、逆合成或新靶标发现；课程允许选择其中一项预测任务，本项目选定并完整实现了 BACE pIC50 活性预测这一项。

结论

在小样本 BACE-1 抑制活性预测上，零调参的表格基础模型 TabPFN 给出最优点估计，并在统计显著性、骨架外推鲁棒性、conformal 条件覆盖三条轴上对新化学的泛化均达第一梯队或最稳；模型误差系统性集中在活性悬崖、标签冲突与新骨架，且可被不确定性预警（支持拒识策略）；结构方法（对接

PBCNet2) 在 cross-docking 位姿域未能超过配体模型, 构成一个界定适用范围的阴性结果。全程以阴性对照、泄漏审计与显著性检验自检, 结论既可被质疑也可被辩护。

参考文献

- [1] VASSAR R, BENNETT B D, BABU-KHAN S, et al. β -secretase cleavage of Alzheimer's amyloid precursor protein by the transmembrane aspartic protease BACE[J]. Science, 1999, 286(5440): 735-741. DOI: 10.1126/science.286.5440.735.
- [2] WU Z, RAMSUNDAR B, FEINBERG E N, et al. MoleculeNet: a benchmark for molecular machine learning[J]. Chemical Science, 2018, 9(2): 513-530. DOI: 10.1039/C7SC02664A.
- [3] SUBRAMANIAN G, RAMSUNDAR B, PANDE V, et al. Computational modeling of β -secretase 1 (BACE-1) inhibitors using ligand based approaches[J]. Journal of Chemical Information and Modeling, 2016, 56(10): 1936-1949. DOI: 10.1021/acs.jcim.6b00290.
- [4] ROGERS D, HAHN M. Extended-connectivity fingerprints[J]. Journal of Chemical Information and Modeling, 2010, 50(5): 742-754. DOI: 10.1021/ci100050t.
- [5] HOLLMANN N, MÜLLER S, PURUCKER L, et al. Accurate predictions on small data with a tabular foundation model[J]. Nature, 2025, 637(8045): 319-326. DOI: 10.1038/s41586-024-08328-6.
- [6] ROSS J, BELGODERE B, CHENTHAMARAKSHAN V, et al. Large-scale chemical language representations capture molecular structure and properties[J]. Nature Machine Intelligence, 2022, 4(12): 1256-1264. DOI: 10.1038/s42256-022-00580-7.
- [7] HEID E, GREENMAN K P, CHUNG Y, et al. Chemprop: a machine learning package for chemical property prediction[J]. Journal of Chemical Information and Modeling, 2024, 64(1): 9-17. DOI: 10.1021/acs.jcim.3c01250.
- [8] CAWLEY G C, TALBOT N L C. On over-fitting in model selection and subsequent selection bias in performance evaluation[J]. Journal of Machine Learning Research, 2010, 11: 2079-2107.
- [9] AKIBA T, SANO S, YANASE T, et al. Optuna: a next-generation hyperparameter optimization framework[C]//Proceedings of the 25th ACM SIGKDD. 2019: 2623-2631. DOI: 10.1145/3292500.3330701.
- [10] DEMŠAR J. Statistical comparisons of classifiers over multiple data sets[J]. Journal of Machine Learning Research, 2006, 7: 1-30.
- [11] MAGGIORA G M. On outliers and activity cliffs — why QSAR often disappoints[J]. Journal of Chemical Information and Modeling, 2006, 46(4): 1535. DOI: 10.1021/ci060117s.
- [12] EBERHARDT J, SANTOS-MARTINS D, TILLACK A F, et al. AutoDock Vina 1.2.0[J]. Journal of Chemical Information and Modeling, 2021, 61(8): 3891-3898. DOI: 10.1021/acs.jcim.1c00203.
- [13] YU J, SHENG X, et al. Atomic-level protein-ligand recognition with PBCNet2.0 for probe discovery[J]. Nature Chemical Biology, 2026. DOI: 10.1038/s41589-026-02241-x.
- [14] ANGELOPOULOS A N, BATES S. Conformal prediction: a gentle introduction[J]. Foundations and Trends in Machine Learning, 2023, 16(4): 494-591. DOI: 10.1561/2200000101.
- [15] ROMANO Y, PATTERSON E, CANDÈS E J. Conformalized quantile regression[C]//NeurIPS 32. 2019.

附录

A. 可复现性审计: 阴性对照: 置换训练标签后用同一流程重训, RF / GBM / TabPFN 测试 Pearson R 分别降至 -0.11 / -0.04 / -0.05, 支持 $R \approx 0.84-0.87$ 来自可学习的结构-活性信号、而非对随机标签的记忆; 泄漏审计: 预定义划分骨架重叠约 64%、约 29% 测试分子 Tanimoto >0.85 , scaffold split 已将相似性虚高剥离 (RF MAE 0.554 $\rightarrow$ 0.684)。统一 set_all_seeds、3 seed、调参只用验证 / 折内 CV、测试集只看一次、所有图由 scripts/ 脚本一键重出。

B. 完整指标 (深度模型 3 seed 均值 $\pm$ 标准差, n=303):

模型	MAE	RMSE	Pearson R	Spearman ρ
TabPFN	0.498	0.668	0.873	0.834
Chemprop	0.551 $\pm$ 0.008	0.737 $\pm$ 0.015	0.842 $\pm$ 0.007	0.827 $\pm$ 0.009
RF	0.554	0.747	0.841	0.822
ChemFM-3B	0.559 $\pm$ 0.022	0.762 $\pm$ 0.021	0.831 $\pm$ 0.009	0.816 $\pm$ 0.007
GBM	0.569	0.753	0.835	0.813
Ridge	0.596	0.796	0.814	0.802
SVR	0.599	0.793	0.815	0.797
MolFormer-XL	0.673 $\pm$ 0.054	0.885 $\pm$ 0.057	0.775 $\pm$ 0.035	0.733 $\pm$ 0.034

C. 数据与代码可用性：本研究使用课程提供的 BACE 数据集与公开蛋白结构 PDB 4D8C；建模、调参、误差解剖、对接、PBCNet2、conformal 与审计脚本及结果表存于项目仓库，经统一入口一键复跑；PBCNet2 代码与权重来自作者公开 MIT 仓库。

D. 配套 JCIM 投稿论文（全文附后）：本项目中跨分子基础模型的 conformal 预测区间评估已扩展为一篇面向《Journal of Chemical Information and Modeling》（JCIM, ACS）的英文论文，题为“Conformal Uncertainty Quantification across Molecular Foundation Models for Small-Sample Regression”，在固定有效覆盖率下系统比较各分子基础模型预测区间的宽度与条件覆盖。该论文正文与补充材料（Supporting Information）作为本报告附录全文附于其后，保留其英文 ACS 双栏排版与独立页码。