

BACE-1 抑制剂活性预测


小样本 QSAR 下表格基础模型、传统模型与分子基础模型的系统评估

Tabular Foundation Models vs Classical QSAR and Molecular Foundation Models on Small-Sample BACE-1

复旦大学《AI 赋能药物发现前沿》期末实验报告 · 课堂汇报

汇报人：汤雨凡（学号 23307130372）

授课教师：戚逸飞 · 王任小 · 李嫣 2026 年 6 月



表格基础模型在三条轴上均达第一梯队，并在外推与条件覆盖上更稳

科学问题：在小样本 BACE QSAR 中，表格基础模型 TabPFN 能否在【点预测】【外推泛化】【不确定性】上达到或超过传统 QSAR 与分子基础模型？

① 点预测

MAE 0.498 最低

与 Chemprop / RF / ChemFM 同属第一梯队；显著性依口径：bootstrap / $\rho=1/9$ 下优于经典基线，保守 NB-Holm 下仅 MolFormer 仍显著更差

② 外推泛化

Δ MAE +0.01 最稳

scaffold split 下几乎不退化；MolFormer 明显退化

③ 可信度

low-AD ~0.9

提示在新化学上更稳；low-AD $n=10$ ，需更大外部集验证


结论（本数据集与评估协议下）：TabPFN 在三轴上达到第一梯队，并在外推 / 低 AD 覆盖上表现最稳；结构方法（对接 / PBCNet2）未能弥补配体模型短板（可能受位姿质量影响）——一并如实报告。

完整回应第五讲作业：数据整理 → 模型构建 → 训练评估 → 药物发现应用

课程环节	本项目对应内容
数据整理	清洗漏斗 / 去重 / Murcko 骨架与泄漏审计
分子表征	Morgan 指纹 + RDKit 物化描述符 + 多指纹消融
模型构建	策略一 传统 ML (RF / GBM / SVR / Ridge) + 基础模型 (MolFormer / ChemFM / TabPFN) ；策略二 Chemprop D-MPNN 图网络
训练与评估	Optuna + 5 折 CV + 3 seed ； MAE / Pearson R · ROC-AUC / MCC · 早期富集 EF
药物发现应用	β -secretase 4D8C 分子对接 (Vina) / PBCNet2 / 活性悬崖分析
可复现性	scaffold split · 泄漏审计 · 阴性对照 · 显著性检验 · conformal / AD 分层

口径：MoleculeNet / DeepChem 作业 (BACE / SMILES / 1513 / 回归 / MAE + Pearson R) ；实现以 RDKit + scikit-learn / Chemprop / HuggingFace Transformers 复现同一数据任务。

研究设计：一个任务、八个模型、三轴评估 + 结构与审计



任务：BACE pIC50 回归 + 结构对接模块（官方 Class 标签为分类口径，本汇报聚焦回归）。指标：MAE / Pearson R 为主，辅以 RMSE / Spearman ρ ；深度模型 3 seed mean $\pm$ sd；测试集 n=303。

八个模型覆盖两种策略，并施加统一的公平性控制

策略一 · SMILES → 编码器 → ML

- 传统 QSAR：随机森林 / 梯度提升 / SVR / 岭回归（Morgan 2048）
- 分子基础模型：MolFormer-XL（47M，全参微调）、ChemFM-3B（30 亿参，LoRA 0.2%）
- 表格基础模型：TabPFN（前向一次、零调参，输入 RDKit 描述符）


策略二 · SMILES → 二维图 → GNN

- Chemprop D-MPNN：原子 - 键有向消息传递图网络
- 覆盖“表征 × 学习器”谱系，回答：表征、规模、还是不调参的基础模型更重要？

公平性控制（避免偏置比较）

- 同一份清洗后划分（base_clean）输入全部 8 个模型；经典模型 Optuna 嵌套交叉验证、折内拟合标准化（防泄漏）；测试集只在最终评估一次。
- 重复性策略不同（非完全统一）：深度模型各 3 seed（报 mean±sd），经典模型与 TabPFN 为确定性单次。


TabPFN 点预测 MAE 最低，与 Chemprop / RF / ChemFM 同属统计第一梯队



证据①：点预测

- TabPFN MAE 0.498 / R 0.873，最优。
- Chemprop、RF、ChemFM 紧随（~0.55）——参数规模不决定性能。
- 逐分子 CD 图（n=303）仅作描述性可视化（分子非独立重复）。
- 严格显著性：配对 bootstrap（10k+Bonferroni）与折级 Nadeau-Bengio 检验。

在本实验预算内，TabPFN 优于 Optuna-tuned baselines




纵轴 test MAE，横轴调参耗时（对数）；红星 = 零调参 TabPFN

成本（效率分析）

- TabPFN：~5 s、0 trial、MAE 0.498。
- GBM 最优需 80 trial / 986 s，仍逊。
- 计时口径：同机 CPU、固定 exhaustiveness / trial 预算、单进程。
- 限定“本实验预算内”，不作绝对结论。

TabPFN 对新骨架最鲁棒，全参微调的 MolFormer 泛化性能明显退化




证据②（外推）


- scaffold MAE : TabPFN 0.51 仍最低、差距最小 ($\Delta+0.01$) 。
- MolFormer 0.67 $\rightarrow$ 1.13 ($\Delta+0.46$)，退化最明显。
- scaffold split = 更严格的新骨架压力测试。

预定义 vs 骨架严格划分的绝对 MAE ; TabPFN 两 split 都最低、差距最小


误差不是随机的：集中在悬崖、标签冲突与新骨架



activity cliff | pIC50=5.7, err=1.91



label conflict | pIC50=8.0, err=2.17



new scaffold (low AD) | pIC50=2.7, err=2.36


跨 8 模型共识最难的三类代表分子

定义：活性悬崖 Tanimoto>0.7 且 $\Delta pIC_{50}>2$ ；标签冲突 = 同 InChIKey14 骨架多标签；“调参不改难” = 默认 / 调参 top-decile 误差集合 Jaccard=0.76。

系统性，不随机

- 回归到均值：低估高活性、高估低活性（TabPFN 收缩最小）。
- 大误差分子：19% 在活性悬崖（其余仅 1%）、16% 标签冲突（其余 2%）。
- 更偏新骨架、极端活性。
- 调参只缩小幅度、不改变“谁难”（大误差集合重叠 76%）。

TabPFN 不确定性能提前标出难分子




按不确定性拒识 → 保留集 MAE 下降 (vs 随机拒识)

可操作的预警

- 主证据：拒识最不确定者 → 保留集 MAE 明显下降 (vs 随机)。
- 区间宽度 vs 误差 Spearman $\rho=0.32$ 。
- 解释性：58% 难例（按 test error 定义，后验）落在 90% 区间外，易预测仅 6%。

边际 90% 覆盖对所有模型都达标




经验覆盖率 vs 区间宽度 (红虚线 = 名义 0.90)

边际有效

- 8 个模型边际覆盖率 0.90–0.95 (达标)。
- Chemprop 区间最紧 (2.26)、TabPFN 次之。
- 协议: split-conformal, 仅用 validation 校准, 全模型同一协议, test 不参与调 coverage。
- 但“边际有效 $\neq$ 处处有效” $\rightarrow$ 下页。

但低相似度（新化学）分子明显欠覆盖




按到训练集 Tanimoto 分层的条件覆盖 (红虚线 = 0.90)

条件覆盖失效

- 8 中 6 个模型低 AD 覆盖率降至 0.2–0.5；TabPFN 与 MolFormer 仍接近 0.9（后者区间更宽）。
- 高 AD 过覆盖 → 边际相互抵消。
- → 边际有效 ≠ 处处有效。
- 局限：低 AD 子群 $n=10$ （小），但欠覆盖方向跨 8 模型一致。

对接打分与活性的相关主要由分子尺寸混淆； docking 价值在结合位姿




Vina 打分 vs 实验 pIC₅₀ (按重原子数着色, n=301)

用途不同，非同类性能比较

- Vina vs 活性：raw $r = -0.33$ ，控尺寸 - 0.17。
- 监督 QSAR 在同一测试集上相关性更高（R 0.84–0.87）。
- 对接价值 = 结合位姿（作为 PBCNet2 输入）。
- 基础对接设置合理：re-dock 1.13 Å（backup）。

结构 - 成对模型在对接位姿上未超过配体模型（可能受位姿质量影响）




活性悬崖对上的相对活性排序 |Spearman|

阴性结果（界定适用范围）

- 悬崖对 $n=161$ ；指标 = |Spearman ρ |（已按 $\Delta\Delta G$ 符号对齐）。
- PBCNet2 0.38（约束 0.17）< RF/TabPFN 0.78。
- 可能主要受 cross-docking 位姿质量限制（非模型本身）。
- 界定适用范围：需晶体 / FEP 级位姿。

换指纹不改模型排名；模型学到真实构效信号




固定随机森林、仅更换分子表征（第五讲指纹清单）

稳健性 + 可解释性

- 表征消融：固定 RF 只换指纹，Morgan / Atom Pair / Topological Torsion 同属第一梯队，MACCS 最弱——模型排名非表征假象。
- RF+Morgan 0.559 $\approx$ 调参后 0.554，互为印证。
- 描述符置换重要性：分子大小 / 复杂度主导（Chi0 $\rho=+0.47$ 、BertzCT），即更大更复杂更强。
- Morgan 子结构可定位增效 / 致弱基团（backup）。
- 呼应课程“可解释性 + 适用域”。

回归之外：分类与早期富集——谁第一随口径而变



8 个模型的 ROC 曲线 (active = $pIC_{50} \geq 7$, 类别均衡 43.9%)

分类 + 早期富集

- 分类 (active = $pIC_{50} \geq 7$) :
Chemprop ROC-AUC 0.915 / MCC 0.650 最高, TabPFN 次之。
- 回归最优 (TabPFN) $\neq$ 分类最优 (Chemprop) ——口径改变排名, 故多轴并看。
- 早期富集 (高活性 = 最高 10%) : 前 5–10% 富集约 4–7 倍于随机; EF@10% ChemFM / RF 领先 (backup)。
- 完整演练第五讲二分类指标 (ROC / PR / F1 / MCC)。

泄漏、随机化与可复现性审计

阴性对照（排除随机标签记忆）

- 置换训练标签后用同一流程重训：RF / GBM / TabPFN 测试 R 分别降至 -0.11 / -0.04 / -0.05 。
- → 支持 $R \approx 0.84-0.87$ 来自可学习的结构 - 活性信号、而非对随机标签的记忆。
- 8 个模型共享同一划分，减少划分差异带来的比较偏置。
- 置换覆盖经典 + 表格代表（RF/GBM/TabPFN）；深度模型未跑置换（成本），但共享同一干净划分。

泄漏审计 + 纪律

- 预定义划分骨架重叠约 64%、约 29% 测试分子 Tanimoto >0.85 。
- scaffold split 已把相似性虚高剥离（RF MAE $0.554 \rightarrow 0.684$ ）。
- 统一 set_all_seeds；3 seed；调参只用验证 / 折内 CV；测试集只看一次；所有图由 scripts/ 脚本一键重出（仓库可查）。

Implications and limitations

Take-home

- 小样本分子回归：零调参 TabPFN 在三轴（点预测 / scaffold 外推 / conformal 可信度）均达第一梯队，并在外推与低 AD 覆盖上、于本实验中表现最稳。
- 误差系统性集中在悬崖 / 标签冲突 / 新骨架；不确定性可提前标出难分子。
- 结构方法（对接 / PBCNet2）未超过配体模型（可能受位姿质量影响）——一个界定适用范围的阴性结果。

Limitations

- 单数据集（BACE），结论外推到其他靶点需验证。
- 预定义划分存在骨架泄漏（已用 scaffold split 缓解并披露）。
- PBCNet2 检验受限于 cross-docking 位姿质量，缺共晶位姿。
- 未做前瞻性实验验证（prospective validation）。

谢谢！恳请老师批评指正。



B

Backup 补充材料





全模型 × 四指标（深度模型 3 seed mean ± sd ；测试集 n=303 ）

模型 (split: predefined)	MAE↓	RMSE↓	Pearson R↑	Spearman ρ↑
TabPFN (desc)	0.498	0.668	0.873	0.834
Chemprop (3 seed)	0.551±0.008	0.737±0.015	0.842±0.007	0.827±0.009
RF + Morgan	0.554	0.747	0.841	0.822
ChemFM-3B (3 seed)	0.559±0.022	0.762±0.021	0.831±0.009	0.816±0.007
GBM	0.569	0.753	0.835	0.813
Ridge	0.596	0.796	0.814	0.802
SVR (RBF)	0.599	0.793	0.815	0.797
MolFormer-XL (3 seed)	0.674±0.054	0.885±0.057	0.775±0.035	0.733±0.034

说明：经典模型与 TabPFN 为确定性单次（重复性策略不同，见 p4 ）；深度模型报 3 seed （ 42/1337/2024 ） mean ± sd 。划分 = bace_clean 预定义。

训练 / 验证 / 测试 + 嵌套交叉验证

```
# MolFormer-XL: SMILES -> molecular vector -> pIC50
enc = tok(smiles, max_length=128, ...)
out = backbone(enc.input_ids, enc.attention_mask)
pooled = masked_mean(out.last_hidden_state, mask)
pred = head(pooled)
# 5 steps: zero_grad -> forward -> MSE
#           -> backward -> clip + step (AdamW +
OneCycleLR)
# best-on-val early stopping; ChemFM LoRA trains 0.2%
```


嵌套交叉验证（经典模型）

- 外层：留出测试只用一次。
- 内层：5 折 CV + Optuna TPE 调参，标准化折内拟合（leak-safe）。
- 避免乐观偏差（Cawley-Talbot 2010）。

防过拟合

- best-on-val 早停；LoRA 0.2%；dropout + 梯度裁剪；经典 5 折 CV。未观察到明显验证 - 测试落差，未见明显过拟合迹象。


默认 vs 调参：欠正则模型大幅受益、树集成边际



调参对岭回归/SVR 大幅提升，对 RF/GBM 仅边际（个别略降）

临界差异图（描述性；Friedman $p=1.3e-5$ ， $n=303$ ）


C Critical-difference diagram (descriptive; Friedman $p=1.3e-05$, per-molecule $n=303$ -- not independent replicates); lower rank = better. Significance: paired bootstrap + per-fold Nadeau-Bengio



逐分子误差平均秩——逐分子非独立重复，仅作描述性可视化，非严格显著性检验


数据质量仪表盘揭示评估风险

BACE data-quality dashboard (1504 molecules)



立体未定义 75% · 骨架重叠约 64% · 测试-训练 Tanimoto · 类药通过率 · 描述符-活性相关

共晶配体 re-dock 支持基础对接设置合理 (RMSD 1.13 Å)




对接位姿 (彩色) 与晶体位姿叠合

为什么 n=301 而非 1504

- 对接为 PBCNet2 提供位姿，对测试集 303 配体对接 (2 个超大柔性失败)。
- Vina 负分 = 更强结合 → 与 pIC50 负相关方向正确。
- 尺寸混淆：活性配体偏大、Vina 偏好大配体。

PBCNet2 接入：成对图 + 两种位姿协议




悬崖 vs 系列对照；cross-dock 与 constrained 两种位姿


Morgan 子结构：增效 / 致弱基团定位

Most predictive Morgan substructures (RF importance) green=potency-up, red=potency-down

bit 964 $\Delta pIC_{50} = -1.73$




bit 1928 $\Delta pIC_{50} = +0.83$




bit 255 $\Delta pIC_{50} = +0.75$




bit 875 $\Delta pIC_{50} = +1.12$



bit 1563 $\Delta pIC_{50} = +0.85$




bit 1855 $\Delta pIC_{50} = -1.21$



随机森林重要性最高的 6 个 Morgan 子结构 (绿 = 增效, 红 = 致弱)

富集曲线 + EF@5% (高活性 = 最高 10%)



潜力命中 = 最高 10% pIC₅₀ ($n=31$, $pIC_{50} \geq 8.04$) ; EF 天花板 9.8