

从零看懂这个项目

AI 怎么帮我们找治阿尔茨海默病的药

复旦大学药学院《AI 赋能药物设计发现前沿》期末项目 · 零基础科普版 · 汤雨凡 (23307130372)

一、先搞懂：这门课到底在解决什么问题

想象一下你要发明一种新药。药，本质上是一个小分子——一小撮原子按特定方式拼起来的“小积木”。它要去人体里找到一个“坏蛋蛋白质”（叫靶点），把它摁住、让它别捣乱，病就好了。

问题来了：能拼出来的小分子有几千万、上亿种。哪一种能摁住坏蛋？传统做法是一个一个拿到实验室里试——合成出来、滴到蛋白上看反应。结果就是：一款新药平均要 **10 年**、烧掉几十亿，每一万个候选分子最后大概只有 1 个能上市。

这太慢太贵了。于是有人想：能不能让电脑先帮我猜？把“大概率有用”的分子挑出来，实验室只去试这几个，剩下的直接淘汰。

打个比方：这就像相亲软件。一个一个真人见面太费时间，软件先根据资料预测“你俩合不合得来”，你只去见匹配度高的。**AIDD (AI 药物设计)** 就是给分子和蛋白做的相亲软件。

这门课《AI 赋能药物设计发现前沿》，学的就是怎么造这个“分子相亲软件”。它的核心只有一句话：怎么让电脑看懂一个分子，然后预测它的某种性质。

二、关键一步：怎么把“分子”喂给电脑

电脑只认数字，不认“分子”。所以第一道坎是：把一个分子变成一串数字。这个“变法”，行话叫表征 (representation, 就是“用什么方式描述这个分子”)。

课程给了两条路（这就是老师反复说的“两种策略”）：

策略一： 分子 → 写成一行文字 (SMILES) → 转成一串数字 → 普通机器学习模型 → 预测

策略二： 分子 → 画成“原子连线图” → 图神经网络 (在图上学) → 预测

- **SMILES** 是啥？就是把分子当成一句话写下来。比如阿司匹林写成 CC(=O)Oc1ccccc1C(=O)O。像把一道菜写成菜谱文字——同一个分子，能用一行字符表示。
- “原子连线图”是啥？把分子画成：原子是点、化学键是线，就像一张社交关系网。

同一个分子，可以用文字描述、也可以用图描述、还可以用它真实的 3D 立体形状描述——描述方式不同，电脑学到的东西就不同。课程的精髓，就是比较这些不同的“描述方式”哪种更好用。

三、这个项目在做什么：挑一把“锁”，做一条龙

期末项目要“选一个预测任务做”。我们选的是 **BACE-1**——这是阿尔茨海默病（老年痴呆）的一个关键坏蛋蛋白。它会切割一种蛋白、产生有害的斑块堆在大脑里。能摁住 **BACE-1** 的分子，就有可能治老年痴呆。

为什么选它？因为它是 6 个候选任务里唯一能把课程所有知识点串成“一条龙”的：

- ① 拿到一堆候选分子 + 它们摁 **BACE-1** 的实测强度
↓
- ② 用 4 种“描述方式”训练电脑，预测“这个分子摁得有多紧”
↓
- ③ 把高活性分子塞进 **BACE-1** 的 3D 结构里，看它怎么卡进去 (分子对接)
↓

④ 对比：电脑预测 vs 物理模拟 vs 真实实验，谁更准

↓

⑤ 追问一句：电脑说“摁得紧”，我到底该不该信？（可信度评估）

一句话：这个项目就是把一个真实的药物设计问题，从数据、建模、3D 结构、一直做到“何时可以相信预测”，走了一个完整闭环。

四、训练用的是什么数据

先说“训练”是什么意思。给电脑看一张大表格：

分子（写成 SMILES）	它摁 BACE-1 有多紧（实测）
分子 A	7.5（很紧）
分子 B	4.2（很松）
...（共 1513 个）...	...

电脑从它见过的分子里找规律（“哦，带这种结构的一般摁得紧”），这叫训练。然后拿它从没见过的分子考它，看它猜得准不准，这叫测试。这就像学生先做例题、再考没做过的卷子——不能拿例题当考题，否则是作弊（这一点后面很重要）。

我们用的数据：

- 课程一共给了 6 个候选任务（水溶性、脂溶性、血脑屏障、BACE.....），作业要求从中选一个来做。我们只选了 **BACE** 这一个任务——用它的 **1513** 个分子，每个都有实验测出的活性。其余 5 个任务我们没做，也没拿来作对比。
- 一张 **BACE-1** 蛋白的“立体照片”：编号 **PDB 4D8C**——科学家用晶体学拍下的这个坏蛋蛋白的真实 3D 长相（里面还卡着一个已知药物）。这是做“分子对接”用的，也是公开数据。

摁住活性强度用的数字叫 **pIC50**——你只要记住：数字越大 = 这个分子摁 **BACE-1** 摁得越紧 = 越可能成药。

五、用了哪些“训练方式”（4 个选手 + 2 个加戏）

就在 **BACE** 这一个任务上，我们让 4 种“描述方式”同台 **PK**（覆盖课程要求的两种策略），看谁预测 BACE 活性最准。用大白话说：

1. 随机森林 + **Morgan** 指纹（老牌选手）。Morgan 指纹 = 给分子做一张体检清单：“含不含苯环？含不含羟基？...”打勾，变成一长串 0/1。随机森林 = 一大群“决策树”投票。比方：用一张特征清单描述一个人（戴眼镜？高个？有胡子？），再让一屋子评委投票猜他职业。
2. **MolFormer-XL**（语言模型选手）。它就是个和 **ChatGPT** 同类的“语言模型”，但读的是分子（SMILES 句子）。它预读了 11 亿个分子，学会了化学的“语感”。
3. **ChemFM-3B**（更大的语言模型）。同上，但更大（30 亿参数）。大不一定好——后面你会看到它在小数据上反而翻车。
4. **Chemprop**（图神经网络）（策略二选手）。把分子当社交网络，让相连的原子互相“传八卦”：每个原子把信息传给邻居，传几轮后，整张图就“理解”了这个分子。

加戏一·分子对接（命中王任小老师的主场）：把蛋白当锁、分子当钥匙，用物理模拟把钥匙往锁孔里塞，打个分：卡得有多稳。比方：把车往车位里倒，给“停得多正”打个分。

加戏二·**Conformal** 预测（可信度）：普通预测只给一个数（“活性 = 7.5”）。但它有多确定？Conformal 让模型改口给一个带保证的范围：“在 6 到 9 之间，而且我这么说 90% 的时候是对的。”比方：天气预报不说“25 度”，而说“20–30 度，90% 把握”——范围越窄越有用，但前提是别吹牛。

六、训练出了什么效果（都是真实跑出来的）

① 谁猜活性最准？**Chemprop**（图网络）赢，Pearson R = **0.835**。R 是衡量“电脑的猜测和真实值排得有多一致”的指标：1 = 完美，0 = 瞎猜，0.835 算相当好。有意思的是：最大的那个模型 **ChemFM-3B** 没赢——在小数据上“大力出不了奇迹”，不是越大越好。

② 分子对接的真相（诚实结论）。先验证模拟靠不靠谱：把一个已知怎么卡的药物重新塞回去，模拟摆出的位置和真实位置只差 **0.92 Å**（埃，极小的距离单位）——几何上完全对，模拟可信。但是！对接打的“卡得稳不稳”分数，几乎预测不了真实活性：打分最高的那个分子，实测活性反而几乎垫底。结论：对接能告诉你分子“怎么卡进去”（可解释的结合姿势），但不能用它来排“谁更有效”。这是诚实话，不吹。

③ “有效不等于好用”（可信度的发现）。在 BACE 上，每个模型给出的预测范围都达到了说好的 **90%** 可靠度（即“有效”）；但最紧的那个合法范围也宽达 ± 1.3 （换算成活性约是 20 倍的区间）——有效，却宽到不太好用。更要紧的是：碰到结构全新、训练时没见过的分子，范围会偏乐观（说有把握、其实没那么准）。所以“电脑说它有把握”得分场景看。

④ 自己拆自己的台（科研诚信）。我们主动查了“作弊”风险：发现数据切分里训练题和考试题有重叠（电脑见过类似的）——把题目严格分开后，成绩从 0.843 掉到 0.778，如实写出来，没藏。还做了个“找茬实验”：把答案故意打乱重训，如果电脑还能猜准，说明它在记噪声；结果它猜不准了 (≈ 0) ——证明 **0.835** 是真本事，不是背答案。

一句话总览

这门课教你怎么让电脑看懂分子、预测它能不能成药；按作业要求从 6 个候选任务里选一个，我们选了阿尔茨海默靶点 **BACE-1**：用它的 1513 个分子当教材，让 4 种“描述分子的方式”（覆盖两种策略）在 **BACE** 上同台比拼，再加上把分子塞进蛋白 **3D** 结构和“何时可以相信预测”两层把关——最后得到：图网络预测最准（**0.835**）、物理对接位置可信但分数不准、预测区间有效却偏宽、对全新结构偏乐观，而且全程自己查自己有没有作弊。